

ANALISIS PERFORMA *PRE-TRAINED MODEL CONVOLUTIONAL NEURAL NETWORK* DALAM KLASIFIKASI KULIT WAJAH

Suhardi Aras¹, Asyrofi Anam², Billy Jes^{*3}, Devid Pratama Sahar⁴

^{1,2,3,4,5} Universitas Muhammadiyah Sorong

Email: ¹suhardi.aras@um-sorong.ac.id, ²asyrofianam0@gmail.com, ³billysorong112@gmail.com,

⁴dvdprtmshr@gmail.com

^{*}Penulis Korespondensi

(Naskah masuk: 07 Juli 2025, diterima untuk diterbitkan: 10 Maret 2026)

Abstrak

Klasifikasi jenis kulit wajah secara otomatis menjadi kebutuhan penting dalam mendukung pemilihan perawatan yang tepat dan objektif. Pendekatan *deep learning* berbasis citra menawarkan solusi yang lebih akurat dibandingkan metode konvensional. Penelitian ini bertujuan untuk menganalisis dan membandingkan performa tiga arsitektur model *pre-trained Convolutional Neural Network* (CNN), yaitu *EfficientNetB7*, *ResNet50*, dan *MobileNetV3* untuk klasifikasi lima kategori. Dataset terdiri dari 1950 gambar wajah yang telah diproses melalui tahapan *preprocessing* serta *augmentation*. Evaluasi dilakukan menggunakan metrik akurasi, *precision*, *recall*, *F1-score*, *confusion matrix*, serta waktu komputasi. Hasil pengujian menunjukkan bahwa *EfficientNetB7* memberikan performa terbaik dengan mencapai akurasi tertinggi sebesar 93%, diikuti oleh *ResNet50* sebesar 91%, dan *MobileNetV3* sebesar 87%. Dengan demikian, arsitektur *EfficientNetB7* menunjukkan kemampuan ekstraksi fitur visual yang lebih unggul dan berpotensi diterapkan pada sistem identifikasi kulit wajah berbasis sistem cerdas.

Kata kunci: kulit wajah, CNN, pre-trained, deep learning

PERFORMANCE ANALYSIS OF *PRE-TRAINED CONVOLUTIONAL NEURAL NETWORK MODELS* FOR FACIAL SKIN CLASSIFICATION

Abstract

Automatic classification of facial skin types has become an important requirement in supporting the selection of appropriate and objective skincare treatments. A deep learning approach based on image analysis offers a more accurate solution compared to conventional methods. This study aims to analyze and compare the performance of three pre-trained Convolutional Neural Network (CNN) architectures, namely *EfficientNetB7*, *ResNet50*, and *MobileNetV3*, for the classification of five categories. The dataset consists of 1,950 facial images that have been processed through preprocessing and augmentation stages. The evaluation was conducted using accuracy, precision, recall, F1-score, confusion matrix, and computational time metrics. The experimental results show that *EfficientNetB7* achieves the best performance with the highest accuracy of 93%, followed by *ResNet50* at 91%, and *MobileNetV3* at 87%. Therefore, the *EfficientNetB7* architecture demonstrates superior visual feature extraction capability and has strong potential to be implemented in intelligent facial skin identification systems.

Keywords: facial skin, CNN, pre-trained, deep learning

1. PENDAHULUAN

Kesalahan dalam mengenali jenis kulit dapat menimbulkan berbagai konsekuensi negatif. Misalnya, penggunaan produk perawatan yang tidak sesuai dapat memperparah kondisi kulit, menyebabkan kulit mengalami iritasi seperti kemerahan, bengkak, dan perih (Binjai, 2024). Di bidang medis seperti dermatologi, identifikasi jenis kulit yang keliru juga dapat menghambat proses diagnosis dan penanganan gangguan kulit secara tepat. Oleh karena itu, identifikasi jenis kulit wajah

yang akurat menjadi sangat penting, baik untuk kebutuhan medis maupun kosmetik.

Klasifikasi kulit wajah tetap merupakan tantangan yang tidak mudah. Faktor-faktor seperti variasi pencahayaan, kualitas gambar, dan ketidakseimbangan jumlah data antar kelas menjadi hambatan signifikan dalam meningkatkan performa model (Yang, Luo and Greer, 2025). Pendekatan tradisional berbasis analisis warna dan tekstur juga sering kali gagal saat dihadapkan dengan gambar dunia nyata yang kompleks (Mbatha et al., 2024).

Berbagai penelitian sebelumnya telah memanfaatkan metode klasifikasi berbasis *machine learning* untuk mengenali jenis kulit wajah. Salah satunya adalah sistem berbasis *Android* yang menggunakan metode *Naïve Bayes* untuk tiga kategori, yaitu normal, kering, dan berminyak. Sistem ini mengubah citra RGB ke *grayscale*, mengekstrak fitur menggunakan GLCM, dan berhasil mengklasifikasi 17 dari 20 data uji dengan akurasi 85% (Indriyani & Sudarma, 2020). Penelitian lain mengusulkan pendekatan berbasis *Support Vector Machine* (SVM) dengan ekstraksi fitur menggunakan *Discrete Wavelet Transform* (DWT), kontras, dan *Local Binary Pattern* (LBP), yang menghasilkan akurasi rata-rata 91.66% dengan waktu proses sekitar 31.57 detik (Alaska et al., 2021).

Studi sebelumnya menunjukkan bahwa metode berbasis fitur manual rentan terhadap variasi pencahayaan dan tekstur sehingga sulit digeneralisir pada citra klinis nyata. Sebaliknya, pendekatan *deep learning* dengan arsitektur CNN mampu mempelajari representasi hierarkis secara otomatis (Adhi Guna et al., 2024). Dalam konteks klasifikasi kulit wajah, model-model *pre-trained* CNN banyak digunakan karena arsitekturnya yang telah terbukti handal dalam berbagai tugas klasifikasi gambar.

Salah satu penelitian membandingkan CNN standar dan *MobileNetV3* untuk klasifikasi lima jenis kulit wajah, yaitu normal, berminyak, berjerawat, kering, dan kombinasi. Hasilnya, *MobileNetV3* menghasilkan akurasi lebih tinggi sebesar 84%, dibandingkan CNN standar yang hanya mencapai 64% (Herimanto et al., 2024). Disisi lain, penelitian memanfaatkan CNN untuk mengklasifikasikan tiga jenis kulit wajah wanita, yaitu normal, kering, dan berminyak, dengan akurasi sebesar 67% (Nissa et al., 2021). Selain itu, sistem klasifikasi kulit wajah berbasis *MobileNetV2* pada perangkat *Android* berhasil mengenali empat kategori dan mencapai akurasi 87.5% dengan waktu komputasi rata-rata 0.4 detik (Marya et al., 2025). Selanjutnya, arsitektur *Inception-v3* juga digunakan untuk klasifikasi kulit kering dan berminyak, yang mampu mencapai akurasi 91.11%, lebih tinggi dibandingkan CNN standar yang hanya sekitar 85% (Ran et al., 2025).

Walaupun salah satu penelitian sebelumnya menunjukkan bahwa arsitektur ringan seperti *MobileNetV2* mampu mengklasifikasikan jenis kulit wajah dengan akurasi mencapai 87.5% dan waktu komputasi rata-rata 0,4 detik pada perangkat *Android*, namun penelitian tersebut hanya menggunakan satu jenis model CNN tanpa perbandingan dengan arsitektur lain yang lebih kompleks dan modern. Evaluasi yang dilakukan pun masih terbatas pada metrik akurasi, tanpa mempertimbangkan *precision*, *recall*, *F1-score*, dan *confusion matrix* yang dapat memberikan gambaran performa model secara menyeluruh.

Penelitian ini hadir untuk melengkapi kekurangan tersebut dengan menganalisis serta

membandingkan performa tiga model *pre-trained* CNN, yaitu *MobileNetV3*, *ResNet50*, dan *EfficientNetB7* dalam klasifikasi jenis kulit wajah. Evaluasi dilakukan menggunakan metrik akurasi, *precision*, *recall*, *F1-score*, *confusion matrix*, serta waktu komputasi untuk menilai efektivitas dan efisiensi dari masing-masing model arsitektur yang digunakan. Keunggulan utama penelitian ini juga terletak pada penggunaan *EfficientNetB7*, arsitektur terbaru yang menawarkan efisiensi parameter lebih baik dan akurasi yang lebih unggul dibandingkan model sebelumnya.

2. METODE PENELITIAN

Penelitian ini menerapkan metodologi pengembangan sistem berbasis *deep learning* dengan menganalisis serta membandingkan tiga arsitektur model *pre-trained* CNN yaitu *MobileNetV3*, *ResNet50*, dan *EfficientNetB7*. Pada tahap awal dilakukan identifikasi permasalahan terkait klasifikasi jenis kulit wajah. Langkah selanjutnya dapat dijabarkan pada poin-poin berikut.

2.1. Dataset

Dataset ini adalah kumpulan citra wajah yang mewakili berbagai kondisi jenis kulit, yang digunakan sebagai dasar dalam pengembangan model klasifikasi berbasis *deep learning*. Data yang digunakan diperoleh dari situs berbagi *dataset* *Kaggle* dengan cara menelusuri dan mengumpulkan gambar berdasarkan kata kunci tertentu yang berkaitan dengan kondisi kulit wajah. Gambar yang terkumpul kemudian dikategorikan ke dalam lima kelas, yaitu normal, berminyak, berjerawat, kering, dan kombinasi, di mana contoh datanya dapat dilihat pada Gambar 1. Total terdapat 750 gambar yang telah divalidasi kembali secara manual untuk memastikan akurasi pelabelan, sehingga data yang digunakan benar-benar mencerminkan kondisi kulit yang sebenarnya dan dapat meningkatkan keakuratan model saat dilatih.



Gambar 1. *Dataset*

Sebagai perbandingan, beberapa penelitian terdahulu juga menggunakan *dataset* dengan karakteristik berbeda, sebagaimana dirangkum pada Tabel 1 berikut:

Tabel 1. Perbandingan *Dataset*


No	Peneliti	Sumber	Jumlah	Kulit
1.	Indriyani et al.	Foto dari klinik kecantikan	60	<i>Normal, Oily, Dry, Combination</i>
2.	Alaska et al.	Foto sendiri	20 (data uji)	<i>Normal, Oily, Dry</i>
3.	Herianto et al.	Kaggle dan scraping dari Bing	521	<i>Normal, Oily, Acne, Dry, Combination</i>
4.	Nissa et al.	Primer (dari HP responden)	20	<i>Normal, Oily, Dry, Combination</i>
5.	Marya et al.	Riset lama dan koleksi baru	Tidak disebutkan	<i>Normal, Oily, Dry, Combination</i>
6.	Ran et al.	54 relawan	648 (augmentasi)	<i>DO, SR, PN, WT (4 dimensi BSTI)</i>

2.2. Preprocessing

Preprocessing merupakan tahap penting dalam meningkatkan fitur pengolahan citra sebelum data digunakan dalam pelatihan model (Widyaya & Budi, 2021). Langkah pertama yang dilakukan adalah mengubah ukuran (*resize*) seluruh citra ke dalam dimensi 224×224 piksel. Ukuran ini dipilih karena merupakan standar input untuk banyak arsitektur *pre-trained* CNN seperti *MobileNetV3*, *ResNet50*, dan *EfficientNetB7*.

Selanjutnya, dilakukan proses normalisasi menggunakan metode standarisasi Z-score untuk menyamakan distribusi nilai input sehingga pelatihan model menjadi lebih stabil dan cepat (Suryanegara et al., 2021). Normalisasi dilakukan menggunakan skema *mean-std normalization* mengikuti distribusi *ImageNet* (*mean* = [0.485, 0.456, 0.406], *std* = [0.229, 0.224, 0.225]). Pendekatan ini memastikan kompatibilitas representasi fitur dengan bobot *pre-trained* sehingga mempercepat konvergensi dan menjaga stabilitas gradien selama *fine-tuning*.

Kemudian, augmentasi data diterapkan guna meningkatkan variasi citra dan memperkecil risiko *overfitting* (Yang et al., 2023). Teknik augmentasi yang digunakan meliputi *resize*, *rotation*, *horizontal flip*, serta penyesuaian acak pada *brightness*, *contrast*, *saturation*, dan *hue*. Proses ini memperkaya variasi visual tanpa merusak struktur gambar, sehingga *dataset* bertambah menjadi 1.950 citra dan membantu meningkatkan keragaman serta akurasi klasifikasi. Contoh hasil augmentasi ditampilkan pada Gambar 2.




Gambar 2. Gambar asli (a) dan hasil augmentasi (b)

2.3. Convolutional Neural Network (CNN)

CNN tergolong ke dalam arsitektur *Deep Neural Network* (DNN) karena memiliki struktur jaringan yang dalam dan kompleks, yang membuatnya mampu menangani volume data yang besar serta mengekstraksi fitur visual dengan sangat baik (Sebatubun & Haryawan, 2024).

CNN terdiri dari beberapa jenis lapisan utama yaitu *convolution layer*, *pooling layer*, dan *fully connected layer*. Arsitektur ini dirancang untuk secara otomatis mengekstraksi fitur penting dari gambar dan melakukan klasifikasi secara *end-to-end*.



Gambar 3. Arsitektur CNN

Proses awal dalam CNN dimulai dari *convolution layer* yang berfungsi untuk mengekstraksi fitur visual dari citra masukan. Pada lapisan ini, sejumlah filter diterapkan untuk menangkap pola lokal seperti tepi, tekstur, dan sudut. Setiap hasil konvolusi kemudian diteruskan ke fungsi aktivasi, seperti *ReLU* (*Rectified Linear Unit*), guna menambahkan sifat *non-linear* pada data yang diproses.

Setelah melalui *convolution*, data akan diproses oleh *pooling layer*, seperti *max pooling*, yang bertujuan mengurangi dimensi spasial dari *feature map* sekaligus mempertahankan informasi penting. Proses ini tidak hanya mempercepat waktu komputasi, tetapi juga mengurangi risiko *overfitting* dengan menyederhanakan representasi fitur. Lapisan terakhir dalam CNN adalah *fully connected layer* yang bertugas menghasilkan output akhir berupa prediksi kelas dari citra yang dianalisis.

Untuk meningkatkan akurasi dan efisiensi pelatihan, serta mengurangi nilai *error*, penelitian ini menggunakan pendekatan *transfer learning* dengan memanfaatkan arsitektur *pre-trained* model CNN, yaitu *MobileNetV3*, *ResNet50*, dan *EfficientNetB7*. *Pre-trained* model merupakan arsitektur CNN yang telah dilatih sebelumnya pada *dataset* berskala besar seperti *ImageNet*. Dengan demikian, bobot awal model sudah mengandung kemampuan mendasar dalam mengenali berbagai fitur visual umum. Hal ini mempercepat pelatihan dan meningkatkan performa, terutama pada *dataset* khusus seperti citra kulit wajah.

MobileNetV3 merupakan pengembangan terbaru dari arsitektur *MobileNets*, yang ditujukan untuk memenuhi berbagai kebutuhan komputasi, baik dengan daya sumber tinggi maupun rendah. *MobileNetV3* menggunakan algoritma *NetAdapt*, alat *Network Architecture Search* (NAS) yang dirancang

untuk mengidentifikasi struktur model yang paling efisien, mengoptimalkan ukuran kernel, dan mengadaptasi arsitektur jaringan ke berbagai platform keras (Suwarno et al., 2023). Dalam penelitian ini, peneliti menggunakan satu model dari arsitektur *MobileNet*, yaitu *MobileNetV3-Large*. Model ini dipilih karena memiliki jumlah lapisan yang lebih banyak, yaitu sebanyak 15 layer, sehingga dapat menangkap fitur visual secara lebih efektif dan menghasilkan performa klasifikasi yang lebih optimal sesuai dengan kebutuhan sistem (Rakhmat & Haekal, 2023).

Selain itu, arsitektur ini juga memiliki keunggulan dengan penggunaan fungsi aktivasi *hard-swish*, yaitu versi yang lebih efisien dari fungsi sigmoid (Suwarno et al., 2023). Fungsi ini dapat membantu mengurangi kompleksitas model dan jumlah parameter pelatihan, namun tetap meningkatkan akurasi kompetitif dalam tugas klasifikasi citra.

ResNet50 merupakan salah satu arsitektur model *pre-trained CNN* yang banyak digunakan dalam berbagai tugas klasifikasi gambar karena kemampuannya dalam mengatasi masalah *vanishing gradient*, yang umum terjadi pada jaringan neural yang sangat dalam (Dan, Di and Tradisional, 2025). *ResNet50* memperkenalkan konsep *shortcut connections* yang memungkinkan fitur dari layer sebelumnya langsung ditambahkan ke output layer berikutnya dengan menjaga aliran informasi selama proses pelatihan dan mencegah hilangnya fitur penting akibat bertambahnya kedalaman jaringan (Nashrullah et al., 2020).

Keunggulan arsitektur ini terletak pada kemampuannya mempelajari representasi fitur visual yang kompleks secara mendalam tanpa menurunkan akurasi maupun performa model secara keseluruhan. Dengan 50 lapisan dan struktur yang terdiri dari lima tahap konvolusi yang diakhiri dengan proses *average pooling* dan *fully connected layer*, *ResNet50* dirancang untuk mempertahankan efisiensi pelatihan serta kestabilan gradien (Nashrullah et al., 2020). Kemampuan ini menjadikan *ResNet50* sangat cocok untuk berbagai aplikasi visual, termasuk klasifikasi citra dan deteksi objek, di mana akurasi tinggi dan efisiensi komputasi menjadi hal yang krusial.

EfficientNetB7 merupakan salah satu arsitektur arsitektur deep learning yang paling terkenal dalam hal efisiensi komputer dan kinerja klasifikasi. Arsitektur ini didasarkan pada teknik *scalling* yang efektif, sehingga dapat menghasilkan model dengan akurasi tinggi tanpa memerlukan penggunaan parameter tambahan (Arnandito & Sasongko, 2024). *EfficientNet* terdiri dari berbagai variasi model, dimulai dengan *EfficientNetB0* hingga *EfficientNetB7*, yang masing-masing memiliki jumlah parameter dan kompleksitas yang terus meningkat. *EfficientNetB7* merupakan varian terbesar dengan sekitar 66 juta parameter, yang menawarkan potensi peningkatan akurasi secara signifikan dengan

menyesuaikan skala model (Arnandito & Sasongko, 2024).

Keunggulan utama *EfficientNetB7* terletak pada penggunaan teknik *compound scaling*, yang secara seimbang meningkatkan kedalaman, lebar, dan resolusi input, serta mengintegrasikan blok standar CNN dan *MBConv* untuk meningkatkan efisiensi pemrosesan data (Setyawan et al., 2024). Meskipun membutuhkan sumber daya komputasi lebih besar, *EfficientNetB7* menawarkan performa tinggi yang menjadikannya cocok untuk tugas klasifikasi visual yang menuntut akurasi, seperti pengenalan jenis kulit wajah.

Proses *fine-tuning* dilakukan dengan membekukan (*freeze*) seluruh *convolutional base* pada tahap awal untuk mempertahankan fitur umum dari *ImageNet*. Lapisan klasifikasi akhir diganti dengan *fully connected layer* baru berukuran 2560-5 dan dilatih ulang. Setelah konvergensi awal, dilakukan *unfreezing* bertahap pada blok akhir jaringan untuk memungkinkan adaptasi fitur tingkat tinggi terhadap karakteristik tekstur kulit wajah.

Setelah melewati arsitektur utama dari model *pre-trained CNN*, akan dilakukan penyesuaian dengan menambahkan lapisan *dropout* bernilai 0.5 untuk mengurangi *overfitting* dan lapisan *fully connected* yang mengubah *output* dari 2560 menjadi 5 sesuai jumlah kelas. Selanjutnya, fungsi *CrossEntropyLoss* digunakan untuk menghitung probabilitas kelas secara efisien melalui kombinasi *softmax* dan *negative log-likelihood*.

2.4. Pelatihan

Proses pelatihan dilakukan selama 50 *epoch* menggunakan pendekatan *transfer learning* berbasis *supervised learning* dengan tiga model *pre-trained CNN*, yaitu *EfficientNetB7*, *ResNet50*, dan *MobileNetV3*. Ketiganya telah dilatih pada *dataset ImageNet* dan dimodifikasi pada bagian klasifikasi akhir agar sesuai dengan lima kelas jenis kulit wajah, yaitu normal, berminyak, berjerawat, kering, dan kombinasi. Setelah penyesuaian, model dilatih menggunakan *dataset* yang telah melalui proses augmentasi dan *preprocessing*.

Selanjutnya, untuk mengoptimalkan proses pembelajaran, digunakan *optimizer Adam (Adaptive Moment Estimation)* yang bersifat adaptif dalam mengatur bobot dan *learning rate* berdasarkan momen pertama dan kedua dari *gradient*. Adam dipilih karena mampu mempercepat konvergensi dan lebih efektif menangani *sparse gradients* dibandingkan *optimizer* konvensional seperti *RMSprop*. (Syifa & Dewi, 2022). Pemilihan Adam diperkuat oleh hasil penelitian sebelumnya yang menunjukkan Adam memperoleh akurasi sebesar 98.89%, dibandingkan dengan *RMSprop* sebesar 96.67%, dan Adamax sebesar 88.89% dalam pelatihan model CNN (Dharma et al., 2026).

Selain itu, penggunaan Adam didukung oleh *learning rate scheduler StepLR* dan pengaturan *batch*

size yang tepat. *Learning rate* yang sesuai mencegah pelatihan lambat atau tidak stabil, sementara *batch size* menentukan jumlah data untuk setiap *epoch* agar proses pelatihan tetap efisien dan stabil. (Rochmawati et al., 2021). Dalam penelitian ini, digunakan *learning rate* sebesar 0.0001 karena cukup kecil untuk menjaga kestabilan pembaruan bobot, namun tetap memungkinkan model belajar secara efisien. Nilai ini diturunkan secara bertahap setiap 15 *epoch* dengan faktor pengurang (*gamma*) 0.1 untuk mencegah *overfitting*. Sementara itu, *batch size* sebesar 16 dipilih karena mampu menyeimbangkan antara kecepatan pelatihan dan kestabilan perubahan bobot selama proses optimasi.

2.5. Pengujian

Setelah proses pelatihan selesai, setiap model diuji menggunakan *dataset* yang telah benar-benar dipisahkan dari data pelatihan dan validasi. Pengujian dilakukan untuk menilai performa generalisasi model dalam mengenali jenis kulit wajah pada data yang belum pernah dilihat sebelumnya. Pengujian dilakukan secara konsisten terhadap ketiga arsitektur *pre-trained CNN* yang digunakan dalam penelitian ini, yaitu *EfficientNetB7*, *ResNet50*, dan *MobileNetV3* dilakukan evaluasi menggunakan metrik yang sama.

Penelitian ini menggunakan berbagai metrik evaluasi untuk menilai performa model secara menyeluruh. Akurasi digunakan untuk mengetahui seberapa besar prediksi yang tepat dari keseluruhan data, *precision* dan *recall* menilai kemampuan model dalam mengenali tiap kelas secara akurat dan konsisten, sedangkan *F1-score* memberikan keseimbangan antara keduanya, terutama saat jumlah data antar kelas tidak seimbang. *Confusion matrix* membantu menampilkan distribusi prediksi benar dan salah, sementara waktu komputasi digunakan untuk mengukur efisiensi model. Gabungan metrik ini tidak hanya membantu memilih model dengan performa terbaik, tetapi juga memastikan bahwa model tersebut layak diterapkan dalam sistem nyata yang membutuhkan akurasi tinggi dan respons cepat.

2.6. Google Colaboratory

Penelitian ini dilakukan menggunakan *Google Colaboratory* (Colab), platform pengembangan berbasis *cloud* yang mendukung pemrograman *Python* dengan akses ke sumber daya komputasi seperti CPU, GPU, dan TPU. Colab juga telah dilengkapi pustaka populer seperti *PyTorch*, *TensorFlow*, dan *NumPy*, sehingga memudahkan pelatihan model *deep learning* tanpa perlu konfigurasi perangkat lokal (Gelar Guntara, 2023).

Sistem klasifikasi jenis kulit wajah dalam penelitian ini dikembangkan dan dijalankan sepenuhnya di *Google Colaboratory* karena stabilitas server, kemudahan integrasi dengan *Google Drive*, serta efisiensi dalam menangani proses komputasi intensif selama pelatihan dan evaluasi model, dengan

spesifikasi perangkat keras berupa GPU NVIDIA Tesla T4 yang diimplementasikan menggunakan *Python* 3.10 serta framework *PyTorch*, *TensorFlow*, dan *NumPy*.

2.7. PyTorch

Dalam penelitian ini, kami menggunakan *PyTorch* sebagai *framework* utama untuk pengembangan dan pelatihan model *deep learning*. *PyTorch* dikenal karena fleksibilitasnya dalam membangun dan memodifikasi arsitektur jaringan saraf layaknya menulis kode *Python* biasa, sehingga memudahkan eksplorasi dan eksperimen cepat, terutama untuk tugas kompleks seperti klasifikasi citra wajah. *PyTorch* juga didukung dokumentasi yang luas, komunitas aktif, dan dukungan GPU, sehingga sangat ideal untuk melatih model pada *dataset* berukuran besar. (Iswahyudi et al., 2023).

3. HASIL PENELITIAN DAN PEMBAHASAN

Penelitian ini menggunakan *dataset* citra wajah yang dikumpulkan dari situs berbagi *dataset Kaggle* kemudian dibagi ke dalam lima kelas jenis kulit wajah, yaitu normal, berminyak, kering, berjerawat, dan kombinasi. *Dataset* awal berjumlah 750, dengan distribusi data awal dapat dilihat pada Tabel 2. *Dataset* kemudian ditingkatkan menjadi 1950 gambar melalui proses augmentasi untuk menambah variasi. Data tersebut lalu dibagi menjadi 80% data latih, 10% data validasi, dan 10% data uji, dengan jumlah yang seimbang pada setiap kelas.

Tabel 2. Distribusi awal *Dataset*

Jenis Kulit	Jumlah
Normal	175
Berminyak	121
Kering	128
Berjerawat	190
Kombinasi	136
Total	750

Preprocessing dilakukan melalui *resize* menjadi 224×224 piksel, normalisasi, dan augmentasi. Seluruh tahapan *preprocessing* bertujuan meningkatkan keragaman data serta mengurangi risiko *overfitting*.

Arsitektur CNN yang digunakan adalah tiga model *pre-trained CNN* yaitu *MobileNetV3*, *ResNet50*, dan *EfficientNetB7* dengan dimodifikasi pada bagian klasifikasi akhir agar sesuai dengan lima kelas target. Pelatihan dilakukan selama 50 *epoch* menggunakan *optimizer Adam* dengan *learning rate* awal sebesar 0.0001 yang diturunkan setiap 15 *epoch* menggunakan skema penurunan bertahap dengan faktor *gamma* 0.1 untuk mencegah *overfitting*. Seluruh implementasi dilakukan di *Google Colaboratory* dengan dukungan GPU T4 menggunakan *framework PyTorch*.

Tabel 3. Waktu pelatihan model

Model	Total Waktu
<i>EfficientNetB7</i>	26 Menit 52 detik
<i>ResNet50</i>	16 Menit 45 detik
<i>MobileNetV3</i>	15 Menit 37 detik

Dari sisi efisiensi komputasi pada Tabel 3, ketiga model menunjukkan waktu pelatihan yang berbeda sesuai dengan kompleksitas arsitekturnya. *EfficientNetB7* membutuhkan waktu pelatihan paling lama, yang sejalan dengan jumlah parameter yang besar dan mekanisme *compound scaling* yang meningkatkan kedalaman, lebar serta resolusi jaringan untuk memperoleh akurasi lebih tinggi. Sebaliknya, *ResNet50* mencatat waktu pelatihan lebih cepat dibandingkan *EfficientNetB7* disebabkan struktur *residual connection* memungkinkan proses propagasi gradien yang lebih stabil tanpa menambah kompleksitas komputasi secara signifikan. *MobileNetV3*, menjadi model tercepat yang mencerminkan desain arsitektur *lightweight* yang dioptimalkan untuk efisiensi melalui *depthwise separable convolution* dan neural architecture search (NAS). Perbedaan waktu ini menunjukkan adanya *trade-off* antara akurasi dan efisiensi, dimana model yang lebih kompleks berpotensi memberikan performa klasifikasi lebih tinggi namun memerlukan sumber daya pelatihan yang lebih besar.

Setelah proses pelatihan selesai, evaluasi dilakukan terhadap ketiga model menggunakan data uji. Berikut hasil evaluasi performa utama:

Tabel 4. Perbandingan akurasi model

Model CNN	Akurasi	Precision	Recall	F1-score
<i>EfficientNetB7</i>	0.93	0.94	0.93	0.93
<i>ResNet50</i>	0.91	0.91	0.91	0.91
<i>MobileNetV3</i>	0.87	0.87	0.87	0.86

Berdasarkan Tabel 4, terlihat bahwa model *EfficientNetB7* unggul di semua metrik evaluasi. Keunggulan ini menunjukkan bahwa arsitektur *EfficientNetB7* memiliki kemampuan ekstraksi fitur visual yang lebih mendalam dibandingkan *ResNet50* dan *MobileNetV3*, karena menggunakan pendekatan *compound scaling* yang meningkatkan akurasi tanpa menambah kompleksitas berlebihan.


Tabel 5. Waktu komputasi model

Model	Total Waktu (detik)
<i>EfficientNetB7</i>	0.4
<i>ResNet50</i>	0.2
<i>MobileNetV3</i>	0.5

Tabel 5 menunjukkan *ResNet50* sebagai model tercepat dengan waktu evaluasi 0.2 detik untuk setiap gambar, menjadikannya paling efisien dalam hal kecepatan. Sebaliknya, *EfficientNetB7* mencatat akurasi tertinggi namun membutuhkan waktu 0.4 detik untuk setiap gambar akibat kompleksitas arsitekturnya. Mengingat proses dilakukan di *cloud Google Colaboratory*, waktu komputasi juga dapat dipengaruhi oleh koneksi internet. Oleh karena itu,

pemilihan model perlu disesuaikan dengan kebutuhan, *ResNet50* untuk kecepatan, dan *EfficientNetB7* untuk akurasi.

Percobaan selanjutnya melibatkan keseluruhan evaluasi performa model selama proses pelatihan, dengan mengamati grafik akurasi dan loss pada data training dan validation. Gambar 4 menyajikan hasil visualisasi performa model *EfficientNetB7* selama pelatihan, yang memberikan gambaran mengenai stabilitas dan efektivitas proses model secara menyeluruh.



Gambar 4. Grafik akurasi dan loss model *EfficientNetB7*

Gambar 4 menampilkan grafik akurasi dan *loss* selama 50 *epoch* pelatihan model *EfficientNetB7*. Akurasi data *training* meningkat tajam hingga mendekati 95%, sementara akurasi validasi stabil di kisaran 87% hingga 89% setelah sekitar *epoch* ke-10. Hal ini menandakan bahwa model berhasil mengenali pola dalam data secara efektif, tanpa terjebak pada data pelatihan saja. Meskipun performanya sangat tinggi saat dilatih, model tetap menunjukkan hasil yang konsisten ketika diuji dengan data baru yang belum pernah dilihat sebelumnya.

Pada grafik *loss* menunjukkan penurunan *training loss* secara konsisten hingga di bawah 0.2, menandakan keseluruhan proses berjalan baik. Sementara itu, *validation loss* sempat naik turun pada awal hingga sekitar *epoch* ke-15, lalu stabil mendekati 0.5. Selisih antara keduanya masih wajar, yang berarti model tetap mampu melakukan generalisasi dengan baik pada data baru.


Classification Report:

	precision	recall	f1-score	support
berjerawat	0.90	1.00	0.95	19
kombinasi	0.92	0.79	0.85	14
kering	1.00	0.85	0.92	13
normal	0.89	1.00	0.94	17
berminyak	1.00	1.00	1.00	12
accuracy			0.93	75
macro avg	0.94	0.93	0.93	75
weighted avg	0.94	0.93	0.93	75

Gambar 5. Hasil evaluasi model *EfficientNetB7*

Berdasarkan hasil evaluasi pada Gambar 5, model mencapai akurasi keseluruhan sebesar 93%. Nilai *precision*, *recall*, dan *f1-score* rata-rata berada di angka 0.93 hingga 0.94. Jenis kulit berminyak dan berjerawat berhasil dikenali dengan sangat baik, bahkan nyaris sempurna. Namun, model masih sedikit kesulitan membedakan jenis kulit kombinasi, terlihat dari nilai *recall* yang paling rendah, yaitu


0.79. Meski begitu, performa model tetap tergolong baik dan seimbang dalam mengklasifikasikan sebagian besar jenis kulit wajah.



Gambar 6. Confusion matrix model *EfficientNetB7*

Gambar 6 menunjukkan *confusion matrix* prediksi *EfficientNetB7* terhadap lima kelas kulit wajah. Model menunjukkan performa sangat baik, terutama pada kelas berjerawat dengan 19 prediksi benar dari 20 gambar. Kelas normal dan berminyak juga akurat dengan masing-masing 17 dan 12 prediksi benar. Meski terjadi beberapa kesalahan pada kelas kombinasi dan kering, distribusi prediksi secara keseluruhan cukup merata. Ini membuktikan kemampuan *EfficientNetB7* dalam mengenali fitur visual tiap jenis kulit.

Selain *EfficientNetB7*, model *ResNet50* juga dievaluasi berdasarkan performanya selama proses pelatihan, dengan mengamati grafik akurasi dan *loss* pada data *training* serta *validation*. Gambar 7 menyajikan hasil visualisasi performa model *ResNet50* yang menunjukkan dinamika keseluruhan dan kestabilan pelatihan dari model tersebut.



Gambar 7. Grafik akurasi dan *loss* model *ResNet50*

Pada grafik akurasi di Gambar 7, akurasi data pelatihan meningkat pesat hingga melewati 90% dan stabil di rentang 92% hingga 94% setelah *epoch* ke-15. Sementara itu, akurasi validasi berada di kisaran 85% hingga 88%, menunjukkan performa yang konsisten meskipun sedikit lebih rendah dibandingkan akurasi pelatihan. Ini menandakan bahwa model mampu melakukan generalisasi dengan cukup baik terhadap data baru.

Sedangkan pada grafik *loss*, nilai *loss* pada data pelatihan mengalami penurunan yang konsisten hingga mendekati 0.15, menunjukkan bahwa


keseluruhan proses berjalan stabil. Sementara itu, *loss* pada data validasi terlihat naik-turun dan cenderung stagnan di sekitar 0.4. Kondisi ini mengindikasikan adanya kemungkinan *underfitting* ringan atau *noise* pada data validasi, namun masih dalam batas yang dapat diterima.

Classification Report:

	precision	recall	f1-score	support
berjerawat	1.00	0.95	0.97	19
kombinasi	0.92	0.86	0.89	14
kering	0.86	0.92	0.89	13
normal	0.79	0.88	0.83	17
berminyak	1.00	0.92	0.96	12
accuracy			0.91	75
macro avg	0.91	0.91	0.91	75
weighted avg	0.91	0.91	0.91	75

Gambar 8. Hasil evaluasi model *ResNet50*

Berdasarkan hasil evaluasi pada Gambar 8, model menghasilkan akurasi keseluruhan sebesar 91%, dengan nilai *precision*, *recall*, dan *f1-score* rata-rata yang juga cukup tinggi, yaitu 0.91. Kelas berjerawat dan berminyak menunjukkan performa paling baik, dengan *f1-score* di atas 0.95. Sementara itu, kelas normal memiliki nilai *precision* paling rendah dengan nilai 0.79, yang menunjukkan masih adanya kesalahan dalam memprediksi jenis kulit tersebut. Meskipun begitu, secara umum model tetap menunjukkan kinerja yang baik dalam mengenali lima jenis kulit wajah.




Gambar 9. Confusion matrix model *ResNet50*

Gambar 9 menunjukkan *confusion matrix* hasil prediksi *ResNet50* terhadap data uji. Kelas berjerawat dan normal merupakan dua kelas dengan performa terbaik, masing-masing berhasil diklasifikasikan benar sebanyak 18 dan 15 gambar. Kelas kombinasi dan kering juga menunjukkan hasil yang cukup baik dengan 12 prediksi benar, meskipun terdapat kesalahan klasifikasi sebanyak dua gambar pada masing-masing kelas. Kelas berminyak menunjukkan hasil klasifikasi yang akurat dengan 11 prediksi benar dan satu gambar yang diklasifikasikan sebagai kelas normal.

Secara keseluruhan, *ResNet50* mampu mengklasifikasikan setiap kelas dengan distribusi yang cukup merata dan tingkat kesalahan yang rendah. Kombinasi antara akurasi validasi yang tinggi dan efisiensi waktu evaluasi, yaitu 0.2 detik untuk setiap gambar menjadikan *ResNet50* sebagai model yang seimbang antara performa dan efisiensi, cocok digunakan pada aplikasi *real-time* dengan keterbatasan sumber daya.

Model terakhir yang dievaluasi adalah *MobileNetV3*. Gambar 10 memperlihatkan grafik akurasi dan *loss* selama proses pelatihan, sedangkan Gambar 11 menyajikan hasil evaluasi lengkap berupa metrik akurasi, *precision*, *recall*, dan *F1-score*. Sementara itu, Gambar 12 menunjukkan *confusion matrix* hasil prediksi terhadap data uji.



Gambar 10. Grafik akurasi dan *loss* model *MobileNetV3*

Berdasarkan grafik pada Gambar 10, akurasi pelatihan meningkat dengan cepat dan stabil pada kisaran 92% hingga 94% setelah sekitar *epoch* ke-15. Akurasi validasi terlihat konsisten berada di sekitar 86% hingga 88%, dengan sedikit berubah-ubah pada awal pelatihan. Hal ini menandakan bahwa *MobileNetV3* mampu mencapai stabilitas pelatihan yang baik tanpa mengalami *overfitting* yang berarti.


Dari sisi *loss*, nilai *train loss* mengalami penurunan yang signifikan dan stabil di bawah angka 0.2 setelah *epoch* ke-20, sedangkan *validation loss* tetap berada di kisaran 0.3 dan tidak menunjukkan kenaikan drastis. Ini menunjukkan bahwa model mampu belajar dengan efektif dari data pelatihan dan tetap mempertahankan performa yang baik pada data validasi.

Classification Report:				
	precision	recall	f1-score	support
berjerawat	0.95	1.00	0.97	19
kombinasi	0.79	0.79	0.79	14
kering	0.90	0.69	0.78	13
normal	0.82	0.82	0.82	17
berminyak	0.86	1.00	0.92	12
accuracy			0.87	75
macro avg	0.86	0.86	0.86	75
weighted avg	0.87	0.87	0.86	75

Gambar 11. Hasil evaluasi model *MobileNetV3*

Berdasarkan hasil evaluasi pada Gambar 11, model menghasilkan akurasi sebesar 87%, dengan nilai *precision*, *recall*, dan *f1-score* rata-rata sekitar 0.86 hingga 0.87. Kelas berjerawat dan berminyak menunjukkan performa tertinggi, dengan nilai *recall* sempurna 1.00 dan *f1-score* di atas 0.90. Sebaliknya,

kelas kering dan kombinasi memiliki *recall* yang lebih rendah, yaitu 0.69 dan 0.79, yang berarti model lebih sering salah dalam mengenali dua jenis kulit tersebut. Secara keseluruhan, model masih cukup baik, meskipun akurasinya sedikit lebih rendah dibanding hasil sebelumnya.



Gambar 12. *Confusion matrix* model *MobileNetV3*

Gambar 12 menampilkan *confusion matrix* hasil klasifikasi pada lima kelas. Kelas berjerawat dan berminyak menunjukkan performa yang sangat baik dengan masing-masing 19 dan 12 prediksi benar. Kelas normal juga diklasifikasikan dengan cukup baik, meskipun terdapat dua kesalahan prediksi sebagai kelas kombinasi dan satu sebagai kering. Kelas kombinasi menunjukkan hasil 11 prediksi benar dari 14 data uji, sedangkan kelas kering memiliki performa paling rendah dengan hanya 9 prediksi benar, serta mengalami kesalahan klasifikasi ke empat kelas lainnya.

Secara keseluruhan, *MobileNetV3* memberikan performa klasifikasi yang kompetitif, dengan keunggulan utama pada stabilitas pelatihan dan konsumsi sumber daya yang lebih ringan dibandingkan model lain. Namun, akurasi dan ketepatan prediksi pada kelas kering dan kombinasi masih perlu ditingkatkan untuk mencapai performa setara dengan *EfficientNetB7* atau *ResNet50*. Oleh karena itu, meskipun model ini cocok untuk implementasi pada perangkat terbatas, pengembangannya tetap memerlukan optimasi lanjutan agar dapat digunakan secara lebih luas.

Hasil *confusion matrix* menunjukkan bahwa kesalahan klasifikasi paling sering terjadi antara kelas kulit kombinasi dan kulit kering, yang secara visual memiliki tekstur dan tingkat kilap yang serupa. Model cenderung mengasosikan area pipi yang kering namun memiliki zona-T berminyak sebagai kelas kering secara keseluruhan. Hal ini menunjukkan bahwa perbedaan antar kelas tidak selalu bersifat global tetapi bersifat lokal pada area wajah tertentu. Sebaliknya, kelas berjerawat memiliki tingkat akurasi tertinggi karena keberadaan fitur morfologis yang kontras seperti perubahan warna kulit lebih mudah dipelajari oleh CNN. Temuan ini mengindikasikan bahwa tantangan klasifikasi kulit

wajah bukan hanya pada jumlah data, tetapi pada fine grained visual similarity yang membutuhkan representasi fitur lebih dalam seperti yang dimiliki oleh *EfficientNetB7*.

Sebagai langkah akhir dalam mengevaluasi hasil kontribusi penelitian ini, dilakukan perbandingan antara model terbaik, yaitu *EfficientNetB7* dengan penelitian terdahulu yang juga mengklasifikasikan jenis kulit wajah. Perbandingan difokuskan pada model dan akurasi yang diperoleh, seperti ditampilkan pada Tabel 5.

Tabel 6. Perbandingan hasil penelitian

No	Peneliti	Model	Akurasi
1.	Indriyani et al.	<i>Support Vector Machine (SVM)</i>	91.66%
2.	Alaska et al.	<i>Naïve Bayes</i>	85%
3.	Herimanto et al.	<i>MobileNetV3</i>	84%
4.	Nissa et al.	<i>CNN</i>	67%
5.	Marya et al.	<i>MobileNetV2</i>	87.5%
6.	Ran et al.	<i>Inception-v3</i>	91.11%
7.	Penelitian Ini	<i>EfficientNetB7</i>	93%

Dari Tabel 6 dapat disimpulkan bahwa model *EfficientNetB7* dalam penelitian ini menghasilkan akurasi tertinggi sebesar 93%, melampaui seluruh model pada penelitian terdahulu. Jika dibandingkan dengan metode klasik seperti *Support Vector Machine* oleh (Indriyani & Sudarma, 2020) yang mencapai 91.66% dan *Naïve Bayes* yang digunakan oleh (Alaska et al., 2021) dengan akurasi sebesar 85%, model ini tetap menunjukkan keunggulan yang signifikan. Selanjutnya, dibandingkan dengan *MobileNetV3* oleh (Dharma et al., 2026) yang mencatat akurasi 84% dan *MobileNetV2* oleh (Marya et al., 2025) dengan akurasi 87.5%, *EfficientNetB7* menunjukkan peningkatan performa yang signifikan. Meskipun kedua model *MobileNet* dikenal ringan dan efisien, akurasinya masih di bawah *EfficientNetB7* yang mengoptimalkan kedalaman, lebar, dan resolusi input secara bersamaan. Selain itu, model ini juga melampaui *Inception-v3* yang digunakan oleh (Ran et al., 2025) dengan akurasi 91.11% dan CNN standar dalam penelitian (Anton et al., 2021) yang hanya mencapai 67%, sehingga keunggulan arsitektur *EfficientNetB7* semakin terlihat jelas.

4. KESIMPULAN

Penelitian ini bertujuan untuk mengembangkan sistem klasifikasi jenis kulit wajah dengan menggunakan berbagai arsitektur *pre-trained CNN*, yaitu *EfficientNetB7*, *ResNet50*, dan *MobileNetV3*. Ketiga model tersebut dianalisis serta dibandingkan berdasarkan metrik akurasi, *precision*, *recall*, *F1-score*, *confusion matrix*, dan waktu komputasi, untuk memperoleh gambaran menyeluruh tentang performa dan efisiensi dari masing-masing model. Hasil evaluasi menunjukkan bahwa seluruh model memiliki kemampuan yang cukup baik dalam mengklasifikasikan lima jenis kulit wajah, yakni normal, berminyak, kering, berjerawat, dan

kombinasi. Kesalahan klasifikasi terutama terdapat antara kelas kering dan kombinasi karena keduanya memiliki distribusi fitur lokal yang tumpang tindih. CNN cenderung mengekstraksi fitur global sehingga kesulitan menangkap variasi spasial parsial.

Dari hasil perbandingan, *EfficientNetB7* muncul sebagai model terbaik dalam penelitian ini dengan akurasi tertinggi dan performa yang konsisten di hampir seluruh kelas. Hal ini tidak lepas dari keunggulan arsitektur *EfficientNetB7* yang menggunakan teknik *compound scaling*, yaitu pendekatan sistematis untuk mengatur kedalaman, lebar, dan resolusi input secara seimbang. Meskipun waktu komputasi *EfficientNetB7* sedikit lebih tinggi dibanding *ResNet50*, hasil klasifikasinya lebih stabil, khususnya pada kelas dengan jumlah data yang lebih sedikit seperti kulit kombinasi dan kering. Sebaliknya, *ResNet50* memiliki waktu prediksi tercepat, sehingga cocok untuk sistem *real-time* yang memprioritaskan kecepatan, namun sedikit tertinggal dalam hal akurasi.

EfficientNetB7 menunjukkan performa tertinggi dalam penelitian ini dengan akurasi mencapai 93%. Keunggulan ini melampaui model-model sebelumnya, termasuk pendekatan klasik seperti SVM dengan akurasi 91,66% (Indriyani & Sudarma, 2020) dan *Naïve Bayes* dengan akurasi 85% (Alaska et al., 2021). Selain itu, *EfficientNetB7* juga melampaui berbagai arsitektur berbasis *deep learning* sebelumnya, seperti *MobileNetV3* dengan akurasi 84% (Dharma et al., 2026), CNN standar dengan akurasi 67% (Anton et al., 2021), *MobileNetV2* dengan 87.5% (Marya et al., 2025), serta *Inception-v3* dengan 91.11% (Ran et al., 2025).

Dengan demikian, arsitektur *EfficientNetB7* terbukti memiliki kemampuan ekstraksi fitur visual yang lebih unggul dalam mengenali karakteristik jenis kulit wajah. Keunggulan ini membuka peluang pemanfaatannya dalam pengembangan *explainable AI* berbasis Grad-CAM untuk meningkatkan interpretabilitas sistem.

DAFTAR PUSTAKA

- ADHI GUNA, E., FRANSISKA SIHOMBING, E., NICO PASARIBU, M., SYAHPUTRA, H. AND RAMADHANI, F., 2024. Implementasi Algoritma Cnn Dalam Mengidentifikasi Tingkat Keparahan Jerawat Pada Wajah. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 8(4), pp.5778–5782.
<https://doi.org/10.36040/jati.v8i4.10010>.
- ALASKA, K.P., INDRAWATI, I. AND HIDAYAT, H.T., 2021. Klasifikasi Citra Kulit Wajah Menggunakan Metode Naïve Bayes Berbasis Android. *Journal of Artificial Intelligence and Software Engineering (J-AISE)*, 1(1), p.16.
<https://doi.org/10.30811/jaise.v1i1.2217>.

- ANTON, A., NISSA, N.F., JANIATI, A., CAHYA, N. AND ASTUTI, P., 2021. Application of Deep Learning Using Convolutional Neural Network (CNN) Method For Women's Skin Classification. *Scientific Journal of Informatics*, 8(1), pp.144–153. <https://doi.org/10.15294/sji.v8i1.26888>.
- ARNANDITO, S. AND SASONGKO, T.B., 2024. Comparison of EfficientNetB7 and MobileNetV2 in Herbal Plant Species Classification Using Convolutional Neural Networks. *Journal of Applied Informatics and Computing*, 8(1), pp.176–185. <https://doi.org/10.30871/jaic.v8i1.7927>.
- ASHARI RAKHMAT, G. AND FIKRI HAEKAL, M., 2023. MIND (Multimedia Artificial Intelligent Networking Database Peningkatan Performa MobilenetV3 dengan Squeeze-and-Excitation (Studi Kasus Klasifikasi Kesegaran Ikan Berdasarkan Mata Ikan). *Journal MIND Journal | ISSN*, [online] 8(1), pp.27–41. Available at: <<https://doi.org/10.26760/mindjournal.v8i1.27-41>>.
- BINJAI, K., 2024. Korelasi Permasalahan Kulit Wajah terhadap Jenis Produk yang Digunakan Menggunakan Metode Apriori (Studi Kasus : Queen Arabic). (4).
- DAN, B., DI, S. AND TRADISIONAL, P., 2025. IMPLEMENTASI CNN RESNET50 UNTUK MENDETEKSI KUALITAS. 9(3), pp.3675–3682.
- DHARMA, A.S., AMALIA, J., LARGO, D., ADELIA, C. AND SIHITE, P., 2026. Performance Analysis of MobileNetV3-based Convolutional Neural. 5(158), pp.701–709.
- GELAR GUNTARA, R., 2023. Pemanfaatan Google Colab Untuk Aplikasi Pendeteksian Masker Wajah Menggunakan Algoritma Deep Learning YOLOv7. *Jurnal Teknologi Dan Sistem Informasi Bisnis*, 5(1), pp.55–60. <https://doi.org/10.47233/jteksis.v5i1.750>.
- INDRIYANI AND MADE SUDARMA, I., 2020. Classification of facial skin type using discrete wavelet transform, contrast, local binary pattern and support vector machine. *Journal of Theoretical and Applied Information Technology*, 98(5), pp.768–779.
- ISWAHYUDI, I., HINDARTO, D. AND SANTOSO, H., 2023. PyTorch Deep Learning for Food Image Classification with Food Dataset. *Sinkron*, 8(4), pp.2651–2661. <https://doi.org/10.33395/sinkron.v8i4.12987>.
- LIANG, S., TONY TAN AND JONATHAN, J., 2023. MobileNetV3-based Handwritten Chinese Recognition Towards the Effectiveness of Learning Hanzi. *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 7(6), pp.1394–1402. <https://doi.org/10.29207/resti.v7i6.5505>.
- MARYA, D., MUSTIKA, C., RAMADHANI, S. AND ARDIANSYAH, R., 2025. Development of an Optimized Facial Skin Type Classification System using CNN MobileNetV2 for Real-Time Smartphone Applications. 15(1), pp.1–8.
- MBATHA, S.K., BOOYSEN, M.J., THEART, R.P., JUNAYED, M.S., JENY, A.A., ATIK, S.T. AND NEEHAL, N., 2024. Skin Tone Estimation under Diverse Lighting Conditions. 2019 12th International Conference on Information & Communication Technology and System (ICTS), 10(5), pp.1–25. <https://doi.org/10.3390/jimaging10050109>.
- NASHRULLAH, F., WIBOWO, S.A. AND BUDIMAN, G., 2020. The Investigation of Epoch Parameters in ResNet-50 Architecture for Pornographic Classification. *Journal of Computer, Electronic, and Telecommunication*, 1(1), pp.1–8. <https://doi.org/10.52435/complete.v1i1.51>.
- RAN, J., DONG, G., YI, F., LI, L. AND WU, Y., 2025. Automatic Measurement of Comprehensive Skin Types Based on Image Processing and Deep Learning. *Electronics (Switzerland)*, 14(1), pp.1–21. <https://doi.org/10.3390/electronics14010049>.
- ROCHMAWATI, N., HIDAYATI, H.B., YAMASARI, Y., TJAHYANINGTIJAS, H.P.A., YUSTANTI, W. AND PRIHANTO, A., 2021. Analisa Learning Rate dan Batch Size pada Klasifikasi Covid Menggunakan Deep Learning dengan Optimizer Adam. *Journal of Information Engineering and Educational Technology*, 5(2), pp.44–48. <https://doi.org/10.26740/jieet.v5n2.p44-48>.
- SEBATUBUN, M.M. AND HARYAWAN, C., 2024. Implementasi Algoritma Convolutional Neural Network untuk Klasifikasi Jenis Keris. *Jurnal Teknologi Informasi dan Ilmu Komputer*, 11(3), pp.595–602. <https://doi.org/10.25126/jtiik.937260>.
- SETYAWAN, A.F., HASANI, R.A. AND ARUMI, E.R., 2024. Sistem Klasifikasi Keanekaragaman Tanaman Pangan Menggunakan Transfer Learning Pendekatan CNN dan Model Arsitektur. 6(1), pp.66–75. <https://doi.org/10.47065/josh.v6i1.5577>.
- SURYANEGARA, G.A.B., ADIWIJAYA AND PURBOLAKSONO, M.D., 2021. Peningkatan Hasil Klasifikasi pada Algoritma Random Forest untuk Deteksi.

- Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 1(10), pp.114–122.
- SYIFA, S.A. AND DEWI, I.A., 2022. Arsitektur Resnet-152 dengan Perbandingan Optimizer Adam dan RMSProp untuk Mendeteksi Penyakit Paru – Paru. *MIND (Multimedia Artificial Intelligent Networking Database) Journal*, [online] 7(2), pp.139–150. Available at: <<https://doi.org/10.26760/mindjournal.v7i2.139-150>>.
- WIDYAYA, J.E. AND BUDI, S., 2021. The Effect of Preprocessing on the Classification of Diabetic Retinopathy with the Transfer Learning Convolutional Neural Network Approach. *Jurnal Teknik Informatika dan Sistem Informasi*, 7(1), pp.110–124.
- YANG, G., LUO, S. AND GREER, P., 2025. Advancements in skin cancer classification: a review of machine learning techniques in clinical image analysis. *Multimedia Tools and Applications*, [online] 84(11), pp.9837–9864. <https://doi.org/10.1007/s11042-024-19298-2>.
- YANG, Z., CHERIAN, S. AND VUCETIC, S., 2023. Data Augmentation for Radiology Report Simplification. *EACL 2023 - 17th Conference of the European Chapter of the Association for Computational Linguistics, Findings of EACL 2023*, pp.1877–1887. <https://doi.org/10.18653/v1/2023.findings-eacl.144>.

Halaman ini sengaja dikosongkan