

ADAPTIVE ENSEMBLE CNN–BILSTM UNTUK INTEGRASI CITRA AWAN DAN DATA METEOROLOGI BMKG DALAM PREDIKSI CUACA JANGKA PENDEK DI MANOKWARI

Ridho Nur Fauzi^{*1}, Julius P. P Naibaho², Alex De Kweldju³

^{1,2,3}Universitas Papua, Manokwari

Email: ¹ridho.nurfauzi123@gmail.com, ²ridho.nurfauzi123@gmail.com, ³ridho.nurfauzi123@gmail.com

^{*}Penulis Korespondensi

(Naskah masuk: 29 Maret 2026, diterima untuk diterbitkan: 12 Mei 2026)

Abstrak

Penelitian ini mengusulkan model *Adaptive Ensemble CNN–BiLSTM* untuk meningkatkan konsistensi dan performa rata-rata prakiraan cuaca jangka pendek (1–3 jam) di wilayah tropis Manokwari, Papua Barat. Model *Adaptive Ensemble* dibangun dengan mengintegrasikan citra awan multisumber, data meteorologi BMKG, serta metadata waktu dan lokasi. *Convolutional Neural Network (CNN)* digunakan untuk mengekstraksi fitur spasial, sedangkan *Bidirectional Long Short-Term Memory (BiLSTM)* memodelkan dinamika temporal deret waktu atmosfer. Mekanisme *Adaptive Ensemble* menggabungkan prediksi CNN dan BiLSTM dengan bobot dinamis, sehingga performa rata-rata meningkat signifikan dibandingkan baseline sederhana maupun *Conditional Ensemble*. Evaluasi dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, dan *macro F1* pada horizon H+1, H+2, dan H+3, serta uji statistik (*McNemar*, *paired t-test*, *Wilcoxon*, *Cohen's Kappa*, dan *Balanced Accuracy*). Hasil menunjukkan bahwa BiLSTM unggul dalam *global accuracy* (88–89%, *macro F1* 0.88), sementara *Adaptive Ensemble* menghasilkan *accuracy* 87–90% dengan *macro F1* 0.84–0.88. Uji *paired t-test* signifikan ($p = 0.017$) menegaskan bahwa *Adaptive Ensemble* unggul secara rata-rata, dengan distribusi kesalahan yang lebih konsisten lintas horizon. Analisis metadata memperlihatkan bahwa *Adaptive Ensemble* lebih unggul pada siang hari (*accuracy* 0.90–0.94, *F1* 0.83–0.92), sedangkan *Conditional Ensemble* lebih stabil pada malam hari (*accuracy* 0.81–0.82, *F1* 0.80–0.81). Evaluasi antar kelurahan menunjukkan mayoritas *accuracy* *Adaptive Ensemble* berada pada kisaran 0.80–0.92, dengan pengecualian Udopi yang lebih rendah (0.652, *F1* 0.558). Hal ini menandakan distribusi relatif seimbang tanpa bias ekstrem, meskipun jumlah data memengaruhi variasi performa. Kontribusi utama penelitian ini adalah integrasi multimodal CNN–BiLSTM dengan *Adaptive Ensemble* serta evaluasi berbasis metadata, yang menghasilkan prakiraan cuaca lokal lebih akurat secara rata-rata sekaligus relevan lintas waktu dan lokasi.

Kata kunci: *cnn, bilstm, adaptive ensemble, conditional ensemble, citra awan, bmk, prakiraan cuaca*

ADAPTIVE ENSEMBLE CNN–BILSTM FOR INTEGRATION OF CLOUD IMAGERY AND BMKG METEOROLOGICAL DATA IN SHORT-TERM WEATHER PREDICTION IN MANOKWARI

Abstract

This study proposes an *Adaptive Ensemble CNN–BiLSTM* model to improve the consistency and average performance of short-term weather forecasts (1–3 hours) in the tropical region of Manokwari, West Papua. The *Adaptive Ensemble* model is built by integrating multi-source cloud imagery, BMKG meteorological data, and time and location metadata. *Convolutional Neural Network (CNN)* is used to extract spatial features, while *Bidirectional Long Short-Term Memory (BiLSTM)* models the temporal dynamics of atmospheric time series. The *Adaptive Ensemble* mechanism combines CNN and BiLSTM predictions with dynamic weights, resulting in a significant improvement in average performance compared to the simple baseline and the *Conditional Ensemble*. Evaluation is carried out using *accuracy*, *precision*, *recall*, and *macro F1* metrics at horizons H+1, H+2, and H+3, as well as statistical tests (*McNemar*, *paired t-test*, *Wilcoxon*, *Cohen's Kappa*, and *Balanced Accuracy*). The results show that BiLSTM excels in *global accuracy* (88–89%, *macro F1* 0.88), while *Adaptive Ensemble* produces 87–90% *accuracy* with *macro F1* 0.84–0.88. A significant *paired t-test* ($p = 0.017$) confirms that *Adaptive Ensemble* is superior on average, with a more consistent error distribution across horizons. Metadata analysis shows that *Adaptive Ensemble* is superior during the day (*accuracy* 0.90–0.94, *F1* 0.83–0.92), while *Conditional Ensemble* is more stable at night (*accuracy* 0.81–0.82, *F1* 0.80–0.81). Evaluation between villages shows that the

majority of Adaptive Ensemble accuracy is in the range of 0.80–0.92, with the exception of Udopi which is lower (0.652, F1 0.558). This indicates a relatively balanced distribution without extreme bias, although the amount of data influences performance variation. The main contribution of this research is the integration of multimodal CNN–BiLSTM with Adaptive Ensemble and metadata-based evaluation, which results in local weather forecasts that are more accurate on average and relevant across time and locations.

Keywords: *cnn, bilstm, adaptive ensemble, conditional ensemble, cloud imagery, bmgk, weather forecast*

1. PENDAHULUAN

Cuaca merupakan faktor penting yang memengaruhi berbagai aktivitas manusia, mulai dari transportasi hingga kegiatan sosial masyarakat. Namun, atmosfer tropis di Manokwari sangat dinamis; kondisi cerah dapat berubah menjadi hujan dalam hitungan jam. Hal ini menjadi tantangan dalam melakukan prakiraan cuaca jangka pendek yang akurat, terutama untuk horizon 1–3 jam ke depan (Nguyen et al., 2022; Suleman & Shridevi, 2022). Prakiraan yang akurat sangat dibutuhkan untuk mendukung sistem peringatan dini serta pengambilan keputusan masyarakat (Supriyadi, 2020).

Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) menyediakan data meteorologi yang cukup kaya untuk membangun model *forecasting*. Sementara itu, citra awan dalam penelitian ini diperoleh dari berbagai sumber terbuka dan dokumentasi pribadi, sehingga menambah variasi visual awan tropis. Periode data yang digunakan terbatas pada 20 Agustus–19 Oktober 2025 (± 2 bulan). Rentang waktu ini belum mencakup variasi musiman tahunan penuh, sehingga penelitian ini diposisikan sebagai studi awal (*pilot study*).

Metode tradisional berbasis statistik sering kali kurang mampu menangkap pola kompleks atmosfer tropis. Pendekatan berbasis *deep learning* lebih menjanjikan, khususnya *Long Short-Term Memory (LSTM)* yang mampu memodelkan ketergantungan jangka panjang dalam data deret waktu (Hochreiter & Schmidhuber, 1997). Namun, LSTM hanya memproses data dalam satu arah. Untuk mengatasi keterbatasan tersebut, dikembangkan *Bidirectional LSTM (BiLSTM)* yang memproses data dari dua arah sekaligus, sehingga lebih efektif dalam menangkap pola temporal yang kompleks (Aswarulloh et al., 2025; Zoremsanga & Hussain, 2024; Hewage et al., 2020; Zhang et al., 2023).

Sejumlah penelitian terdahulu menunjukkan potensi LSTM dan BiLSTM dalam prediksi cuaca *multi-step ahead* (Chandra et al., 2021; Teixeira et al., 2024). Di sisi lain, *Convolutional Neural Network (CNN)* telah digunakan secara luas untuk analisis citra awan (Phung & Rhee, 2019; Zhang et al., 2023; Eslik et al., 2020), namun belum banyak dikombinasikan dengan model temporal seperti BiLSTM dalam konteks lokal Indonesia.

Pendekatan *hybrid CNN–LSTM* terbukti mampu menangkap pola multivariat cuaca secara efektif (Divyashree et al., 2023), sehingga integrasi spasial–temporal dapat dilakukan lebih komprehensif.

Temuan tersebut menjadi pijakan bagi penelitian ini untuk mengembangkan mekanisme *ensemble* adaptif, yang diharapkan mampu menghasilkan prediksi cuaca lokal di Manokwari dengan konsistensi dan relevansi yang lebih tinggi. Dalam konteks lokal, tantangan utama terletak pada variasi spasial antar kelurahan serta perbedaan kondisi siang dan malam, yang belum banyak diintegrasikan dalam model prakiraan berbasis data. Keterbatasan ini berpotensi menimbulkan ketimpangan dalam pemodelan cuaca lokal, sehingga diperlukan pendekatan adaptif yang mempertimbangkan metadata waktu dan lokasi.

Selain itu, penelitian terbaru menunjukkan bahwa pendekatan *adaptive ensemble* berbasis *generative modeling* mampu meningkatkan reliabilitas prakiraan cuaca dengan mengurangi *error* acak dan *bias* sistematis (Nai et al., 2025), serta integrasi AI dengan *ensemble data assimilation* telah digunakan untuk mendiagnosis model prakiraan berbasis *ClimaX* (Kotsuki et al., 2025). Hal ini memperkuat urgensi pengembangan model *Adaptive Ensemble CNN–BiLSTM* dalam penelitian ini, yang dirancang untuk mengintegrasikan citra awan multisumber dengan data meteorologi BMKG serta metadata waktu dan lokasi, sehingga mampu menangkap pola spasial dan temporal secara lebih holistik.

Penelitian ini awalnya menguji *Conditional Ensemble CNN–BiLSTM* dengan bobot α siang/malam sebagai baseline berbasis aturan (*rule-based*) dengan memanfaatkan *mask* siang/malam (*Mday*). Namun, hasil menunjukkan bahwa pendekatan *Conditional* tidak dapat melampaui performa BiLSTM. Oleh karena itu, penelitian ini kemudian mengembangkan *Adaptive Ensemble learning*, di mana bobot CNN dan BiLSTM dipelajari secara otomatis dari data.


Tujuan penelitian ini adalah mengembangkan model *Adaptive Ensemble CNN–BiLSTM* untuk prakiraan cuaca jangka pendek (1–3 jam) di wilayah tropis Manokwari. Model ini dirancang untuk mengintegrasikan citra awan multisumber dengan data meteorologi BMKG serta metadata waktu dan lokasi, sehingga mampu menangkap pola spasial dan temporal secara lebih holistik. Selain itu, penelitian ini juga bertujuan membandingkan performa *Adaptive Ensemble* dengan *Conditional Ensemble* sebagai baseline *rule-based*, serta melakukan evaluasi menggunakan metrik *accuracy*, *precision*, *recall*, *macro F1*, dan uji statistik (McNemar, paired

t-test, *Wilcoxon*, *Cohen's Kappa*, *Balanced Accuracy*) guna menilai konsistensi lintas horizon.

Kontribusi utama penelitian ini terletak pada integrasi multimodal CNN-BiLSTM dalam kerangka *Adaptive Ensemble* yang terbukti meningkatkan konsistensi dan performa rata-rata dibanding baseline sederhana maupun *Conditional Ensemble*. Penelitian ini juga menambahkan dimensi evaluasi *fairness* spasial-temporal, dengan analisis performa siang/malam dan antar kelurahan, sehingga hasil prediksi lebih relevan secara operasional dan tidak bias antar wilayah.

Dengan demikian, penelitian ini menjadi studi awal (*pilot study*) yang dapat menjadi rujukan pengembangan sistem prakiraan cuaca lokal berbasis multimodal di Indonesia, sekaligus membuka arah penelitian lanjutan untuk cakupan data musiman penuh dan integrasi radar/satelit.

2. METODE PENELITIAN



Gambar 1. Alur Metode Penelitian

2.1. Dataset

Penelitian ini menggunakan dua jenis *dataset*, yaitu data meteorologi yang diperoleh dari BMKG dan citra awan dari sumber terbuka serta dokumentasi pribadi. Selain itu, *metadata* berupa informasi waktu dan lokasi digunakan sebagai fitur tambahan untuk meningkatkan konteks lokal prediksi cuaca di wilayah Manokwari pada saat proses *ensemble*.

1. Data meteorologi

Data diperoleh melalui *API* terbuka [BMKG](#) yang disesuaikan untuk wilayah Manokwari pada periode 20 Agustus–19 Oktober 2025, dengan jumlah 14.351 *record* observasi untuk 10 kelurahan di daerah Manokwari, setelah itu data di simpan dalam [Github](#). Pendekatan berbasis data iklim tropis sebelumnya juga telah digunakan untuk prakiraan cuaca dan penyakit berbasis iklim (Nguyen *et al.*, 2022). Variabel yang digunakan meliputi kelurahan, waktu

pengamatan (*datetime*), suhu udara ($^{\circ}\text{C}$), kelembapan relatif (%), curah hujan (mm), kecepatan angin (m/s), arah angin (16 mata angin umum), tutupan awan (%), jarak pandang (km), serta label cuaca. Rentang waktu ± 2 bulan ini belum mencakup variasi musiman tahunan penuh, sehingga penelitian ini dikategorikan sebagai studi awal (*pilot study*). Fokus utama adalah mengevaluasi kelayakan pendekatan multimodal CNN-BiLSTM dengan *Conditional Ensemble* sebagai baseline, serta *Adaptive Ensemble* sebagai metode utama. Data meteorologi terus diperbarui dan dicatat setiap jam, kemudian diolah menjadi deret waktu sepanjang 24 jam untuk horizon prakiraan H+1, H+2, dan H+3.

2. Citra awan

Citra awan diperoleh dari *dataset* terbuka ([Kaggle](#), [Google Image](#)) serta [dokumentasi pribadi](#) di wilayah Manokwari, untuk meningkatkan variasi sekaligus mempertahankan karakteristik lokal citra awan tropis. Jumlah data citra sebesar 2.606 file gambar yang dikategorikan ke dalam tiga kelas utama: Cerah, Berawan, dan Hujan. Seluruh citra diubah ukurannya menjadi 224×224 piksel sebelum diproses oleh CNN. *Dataset* dibagi menjadi tiga subset yaitu data latih, data validasi, dan data uji dengan rasio 70:20:10.

3. Metadata

Metadata digunakan untuk memperkaya konteks spasial-temporal dan menyelaraskan data multimodal. *Metadata* berisi parameter seperti *filename*, label, waktu, kelurahan, dan *is_dark*. Informasi waktu (jam, hari, bulan) diekstraksi menjadi fitur siklik menggunakan fungsi sinus dan cosinus untuk menangkap pola musiman. Informasi lokasi berupa kelurahan dikonversi menjadi variabel dummy melalui teknik *one-hot encoding* sehingga model dapat mempertimbangkan variasi spasial antar wilayah. Dalam *Conditional Ensemble*, *metadata* waktu digunakan untuk membentuk *mask* siang/malam (*Mday*) yang berperan dalam mekanisme *rule-based* penggabungan CNN dan BiLSTM. Sementara dalam *Adaptive Ensemble*, *metadata* tetap digunakan untuk sinkronisasi multimodal dan sebagai fitur tambahan, tetapi bobot CNN dan BiLSTM dipelajari otomatis dari data, sehingga tidak bergantung pada aturan statis. *Metadata* juga menjadi dasar evaluasi *fairness* spasial–

temporal, baik antar horizon maupun antar kelurahan.

2.2. Data Preprocessing

Tahapan *preprocessing* dilakukan untuk memastikan data citra awan dan data meteorologi siap digunakan oleh model CNN-BiLSTM. Proses dibagi menjadi empat jalur sesuai dengan karakteristik data.

1. CNN

Citra awan dinormalisasi ke rentang [0,1] dan dilakukan *augmentation* (rotation, translation, shear, zoom, flip, brightness) untuk mengurangi risiko *overfitting*. Ketidakseimbangan kelas ditangani dengan *class weighting* (Collot et al., 2024), sedangkan label citra diperoleh secara otomatis dari struktur folder *dataset*.

2. Forecasting

Data meteorologi dipetakan dari delapan kategori cuaca (Cerah, Berawan, Cerah Berawan, Udara Kabur, Hujan Ringan, Hujan Sedang, Hujan Petir, Petir) menjadi tiga kelas utama (Cerah, Berawan, Hujan). Fitur waktu (jam, hari, bulan) diekstraksi dalam bentuk siklik (sin/cos), ditambah fitur turunan atmosfer (selisih suhu, kelembapan, tekanan, radiasi). Arah angin dikonversi ke derajat dan vektor x-y, sedangkan lokasi kelurahan di-*encode* dengan teknik *one-hot encoding*. Nilai hilang diimputasi dengan metode *backfill/forward fill*, kemudian seluruh fitur dinormalisasi menggunakan *StandardScaler*.

3. Conditional Ensemble CNN-BiLSTM

Representasi spasial CNN dan temporal BiLSTM digabung melalui mekanisme *Conditional Ensemble*. *Metadata* waktu digunakan untuk membentuk *mask* siang/malam sehingga bobot CNN lebih dominan pada siang hari, sedangkan BiLSTM lebih dominan pada malam hari. *Metadata* citra disinkronkan dengan waktu pengambilan agar prediksi CNN sejajar dengan horizon BiLSTM. Data meteorologi dibentuk menjadi *sequence* 24 jam untuk horizon H+1, H+2, dan H+3. Ketidakseimbangan label ditangani dengan *class weighting* per horizon, sehingga prediksi lebih adil antar kelas maupun wilayah.

4. Adaptive Ensemble CNN-BiLSTM

Berbeda dengan *Conditional Ensemble* yang berbasis aturan siang/malam, *Adaptive Ensemble* mempelajari bobot CNN dan

BiLSTM secara otomatis dari data. Representasi spasial CNN dan temporal BiLSTM digabung dengan bobot dinamis yang dioptimalkan selama pelatihan, sehingga kontribusi masing-masing model dapat menyesuaikan kondisi atmosfer aktual. *Metadata* waktu dan lokasi tetap digunakan untuk menyelaraskan citra dengan deret waktu meteorologi, sementara ketidakseimbangan kelas ditangani dengan *class weighting* per horizon agar distribusi prediksi lebih merata.

2.3. Arsitektur Model

Arsitektur model terdiri atas CNN untuk pemrosesan visual, BiLSTM untuk pemodelan data deret waktu, serta *Conditional Ensemble* sebagai baseline berbasis aturan (*rule-based*) dan *Adaptive Ensemble* sebagai metode utama untuk integrasi multimodal. Pemilihan kombinasi CNN dan BiLSTM dalam kerangka *ensemble* didasarkan pada kebutuhan untuk menggabungkan kekuatan representasi spasial dan temporal secara lebih fleksibel. Literatur sebelumnya menekankan bahwa integrasi CNN dan BiLSTM dalam arsitektur *ensemble* merupakan pendekatan yang relevan untuk meningkatkan konsistensi prediksi pada data kompleks (Kaim et al., 2023). Dalam penelitian ini, konsep tersebut dikembangkan lebih lanjut dengan menambahkan *metadata* lokal (siang/malam, kelurahan) serta mekanisme *adaptive weighting* untuk memastikan *fairness* spasial-temporal pada konteks cuaca tropis Manokwari.

1. CNN

Input citra awan berukuran 224×224 piksel diproses melalui lapisan konvolusi (kernel 3×3, aktivasi ReLU), *Batch Normalization*, dan *MaxPooling*, kemudian diringkas dengan *GlobalAveragePooling2D* serta lapisan *dense* ReLU dengan *dropout* sebelum menghasilkan output *softmax*. Model serupa telah digunakan secara luas untuk klasifikasi awan berbasis darat (Zhang et al., 2018), sehingga relevan untuk menangkap karakteristik visual awan tropis di Manokwari yang kemudian diintegrasikan dengan BiLSTM.

2. Forecasting

Input berupa deret waktu 24 jam dengan fitur atmosfer hasil *preprocessing*. Data diproses melalui *Conv1D* untuk menangkap pola lokal, dilanjutkan dengan dua lapisan BiLSTM (32 dan 16 unit). Representasi temporal kemudian masuk ke lapisan *dense* ReLU dan menghasilkan tiga output *softmax* untuk horizon H+1, H+2, dan H+3. LSTM sendiri telah terbukti efektif untuk prediksi suhu *multi-step* (Zhang et al., 2022), sehingga penggunaan BiLSTM dalam penelitian ini diharapkan mampu

menangkap ketergantungan temporal yang lebih kompleks pada data cuaca tropis.

3. Conditional Ensemble CNN-BiLSTM

Model dibangun dengan menggabungkan representasi spasial CNN dan temporal BiLSTM melalui lapisan *concatenate* untuk membentuk vektor multimodal. Penggabungan dilakukan secara *Conditional*, di mana bobot CNN lebih dominan pada siang hari ketika citra awan lebih informatif, sedangkan BiLSTM lebih dominan pada malam hari. Mekanisme ini diatur oleh parameter bobot dan *mask* siang/malam (*Mday*), dengan formulasi:

$$P_{ens} = \alpha \cdot M_{day} \cdot P_{CNN} + (1 - \alpha \cdot M_{day}) \cdot P_{BiLSTM}$$

Metadata waktu digunakan untuk membentuk *mask* siang/malam, *metadata* citra disinkronkan dengan waktu pengambilan agar sejajar dengan horizon BiLSTM, dan *metadata* lokasi dikonversi dengan *one-hot encoding* untuk menjaga *fairness* antar wilayah. Pendekatan *rule-based weighting* serupa telah digunakan untuk meningkatkan keterampilan prakiraan cuaca musiman melalui pembobotan optimal ensemble (Brajjard et al., 2023). Output akhir model berupa klasifikasi cuaca dengan *softmax*, yang mempertimbangkan informasi visual, temporal, dan *metadata* secara bersamaan. Dengan pendekatan ini, hasil prakiraan cuaca jangka pendek menjadi lebih adil dan reliabel.

4. Adaptive Ensemble CNN-BiLSTM

Adaptive Ensemble dibangun untuk mempelajari bobot penggabungan CNN dan BiLSTM secara otomatis dari data. Mekanisme ini menggunakan keluaran probabilitas CNN (citra awan), BiLSTM (deret waktu meteorologi), serta *metadata* waktu (*mask_day*) sebagai input ke sebuah *neural network* kecil. Arsitektur *Adaptive Ensemble* terdiri atas lapisan *concatenate* untuk menggabungkan probabilitas CNN, BiLSTM horizon H+1, H+2, H+3, dan *mask_day*, lapisan *dense* dengan 128 unit dan aktivasi ReLU (64 unit) untuk mempelajari interaksi antar sumber informasi, lapisan *dropout* dengan *rate* 0.3–0.4 untuk mengurangi *overfitting*, serta tiga lapisan *softmax* output yang masing-masing menghasilkan prediksi cuaca untuk horizon H+1, H+2, dan H+3. Model dilatih menggunakan *Adam optimizer* dengan fungsi kerugian *sparse categorical cross-entropy multi-output*. Proses *training* dilakukan selama 50 *epoch* dengan *batch*

size 32, menggunakan *validation split* 20% dari data uji. Konsep *adaptive ensemble* dalam penelitian ini sejalan dengan tren mutakhir yang menekankan pembelajaran bobot otomatis dari data. Studi terbaru menunjukkan bahwa integrasi *data assimilation* dengan AI dapat meningkatkan konsistensi dan *robustness* prakiraan cuaca (Kotsuki et al., 2025), serta pendekatan *superensemble* generatif mampu mengurangi *error* acak dan *bias* sistematis (Nai et al., 2025). Dengan demikian, *Adaptive Ensemble CNN-BiLSTM* dalam penelitian ini relevan untuk memperkuat stabilitas, *fairness*, dan konsistensi prakiraan cuaca lokal di Manokwari.

2.4. Proses Training

1. Training CNN

Model CNN dilatih menggunakan *dataset* citra awan dengan pembagian seperti pada bagian 2.1. Citra dinormalisasi ke rentang [0,1] dan dilakukan *augmentation* (rotation, translation, shear, zoom, flip, brightness) untuk meningkatkan generalisasi. Arsitektur terdiri atas lapisan konvolusi (kernel 3×3, aktivasi ReLU), *Batch Normalization*, *MaxPooling*, *GlobalAveragePooling2D*, serta lapisan *dense* dengan *dropout*. Optimisasi dilakukan menggunakan *Adam optimizer* dengan *CosineDecay learning rate*, serta fungsi kerugian *categorical cross-entropy* dengan *label smoothing*. Untuk meningkatkan generalisasi, digunakan *dropout*, *early stopping*, dan *ReduceLROnPlateau*. Proses pelatihan berlangsung selama 50 *epoch* dengan *batch size* 32. Formula fungsi kerugian *categorical cross-entropy* dengan *label smoothing* adalah:

$$L = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \cdot \log(\hat{y}_{i,c})$$

2. Training Forecasting

Pada tahap *forecasting* digunakan model BiLSTM yang dilatih dengan *dataset* deret waktu (jendela 24 jam). Fitur dinormalisasi menggunakan *StandardScaler*, ditambah *encoding* waktu (sin/cos), turunan atmosfer, serta vektor angin. Arsitektur terdiri atas *Conv1D*, dua lapisan BiLSTM (32 dan 16 unit), lapisan *dense* ReLU, dan tiga output *softmax* untuk horizon H+1, H+2, dan H+3. Optimisasi dilakukan menggunakan *Adam optimizer* (learning rate = 5e-4) dengan fungsi kerugian *sparse categorical cross-entropy multi-output*. Ketidakseimbangan

kelas ditangani dengan *class weighting* per horizon. Proses pelatihan berlangsung selama 50 *epoch* dengan *batch size* 64. Formula fungsi kerugian *sparse categorical cross-entropy multi-output* adalah:

$$L = \frac{1}{3} \sum_{h=1}^N \left(-\frac{1}{N} \sum_{i=1}^C \log \hat{y}_{i,h} [\hat{y}_{i,h}] \right)$$

3. Training Adaptive Learning

Model *Adaptive Ensemble* dilatih menggunakan keluaran probabilitas CNN, BiLSTM untuk horizon H+1, H+2, dan H+3, serta *metadata* waktu (*mask* siang/malam) sebagai input. Proses *training* dilakukan dengan *Adam optimizer* (learning rate = 1e-3) dan fungsi kerugian *sparse categorical cross-entropy multi-output*. Pelatihan berlangsung selama 50 *epoch* dengan *batch size* 32, menggunakan *validation split* sebesar 20% dari data uji. Untuk menjaga stabilitas, digunakan *callback EarlyStopping* (patience 10, restore best weights) dan *ReduceLROnPlateau* (factor 0.5, patience 5). Ketidakseimbangan kelas ditangani dengan evaluasi berbasis *macro F1*, sehingga performa tidak bias terhadap kelas mayoritas.

2.5. Evaluasi Model

Evaluasi model dilakukan untuk menilai performa CNN, BiLSTM, *Conditional Ensemble* sebagai baseline, serta *Adaptive Ensemble* sebagai metode utama. Selain itu, baseline sederhana seperti *simple averaging* dan *weighted average* tanpa *mask* juga ditambahkan sebagai pembanding. Pengujian dilakukan pada horizon H+1, H+2, dan H+3 untuk menilai konsistensi performa pada jangka waktu yang berbeda.

1. Metrik Evaluasi

Digunakan metrik klasifikasi multikelas: *accuracy*, *precision*, *recall*, dan *macro F1-score*, serta *confusion matrix* untuk melihat distribusi kesalahan antar kelas (Chandra et al., 2021; Suleman & Shridevi, 2022). Formulasi metrik adalah sebagai berikut:

$$Accuracy = \frac{\text{Jumlah Prediksi Benar}}{\text{Total Sampel}}$$

$$Precision_c = \frac{TP_c}{TP_c + FP_c}$$

$$Recall_c = \frac{TP_c}{TP_c + FN_c}$$

$$F1_{macro} = \frac{1}{C} \sum_{c=1}^C \frac{2 \cdot Precision_c \cdot Recall_c}{Precision_c + Recall_c}$$

2. Evaluasi Model Individual

CNN diuji untuk menilai kekuatan representasi spasial citra awan, sedangkan BiLSTM digunakan untuk memodelkan dinamika temporal data meteorologi.

3. Evaluasi Conditional Ensemble

Probabilitas prediksi CNN dan BiLSTM digabung dengan mekanisme *mask* siang/malam (*Mday*). Analisis variasi bobot menunjukkan bahwa CNN lebih dominan pada siang hari, sementara BiLSTM lebih stabil pada malam hari. *Metadata* pada *Conditional Ensemble* berperan penting sebagai penghubung dan pengontrol dalam integrasi CNN-BiLSTM.

4. Evaluasi Adaptive Ensemble

Evaluasi *Adaptive Ensemble learning* dilakukan untuk menilai kemampuan model dalam menggabungkan keluaran CNN dan BiLSTM secara otomatis melalui pembelajaran bobot. Hasil evaluasi ditampilkan dalam bentuk *classification report*, *confusion matrix* per horizon (H+1, H+2, H+3), serta tabel ringkasan *accuracy* dan *macro F1*.

5. Output Evaluasi

Hasil evaluasi ditampilkan dalam metrik *accuracy* dan *macro F1*. Penelitian ini juga menggunakan uji statistik tambahan untuk memperkuat analisis perbandingan model. *McNemar's Test* digunakan untuk menilai apakah distribusi kesalahan antar metode (*Conditional Ensemble* vs *Adaptive Ensemble*) berbeda signifikan pada setiap horizon. Selanjutnya, *paired t-test* dan *Wilcoxon* digunakan untuk menguji signifikansi perbedaan akurasi secara agregat pada ketiga horizon (Yang et al., 2019). Selain itu, *Cohen's Kappa* dan *Balanced Accuracy* digunakan untuk menilai *fairness* antar kelas (Collot et al., 2024; Zhao et al., 2025), sehingga evaluasi tidak hanya menekankan akurasi global tetapi juga konsistensi spasial-temporal. *Fairness* spasial-temporal didefinisikan sebagai konsistensi performa model antar kelurahan dan antar horizon waktu, baik pada *Conditional Ensemble* maupun *Adaptive Ensemble*. Ukuran kuantitatif yang digunakan meliputi variasi *accuracy* dan *macro F1* per kelurahan, serta *Cohen's Kappa* dan *Balanced Accuracy* untuk menilai kesetaraan antar kelas.

Tabel 1. Dataset BMKG

kelurahan	datetime	suhu	kelembapan	curah_hujan	kecepatan_angin	arah_angin	tutupan_awan	jarak_pandang	cuaca
Kel.Amban	2025-08-20 22:00:00	25	92	1.3	21.1	East	100	<6 km	Hujan Ringan
Kel.Amban	2025-08-21 23:00:00	25	91	1.3	17.2	East	100	<7 km	Hujan Ringan
....									
Kp.Udopi	2025-10-19 22:00:00	25	93	0.4	1.5	South West	100	<8 km	Berawan
Kp.Udopi	2025-10-19 23:00:00	25	92	0.4	1.5	South West	100	<8 km	Berawan

Dengan pendekatan ini, evaluasi tidak hanya menekankan akurasi global, tetapi juga distribusi prediksi lintas wilayah dan waktu. Selain itu, baseline sederhana seperti CNN saja, BiLSTM saja, *simple averaging*, dan *weighted average* tanpa *mask* juga dievaluasi untuk memberikan pembandingan yang lebih objektif terhadap performa *ensemble*.

3. HASIL DAN PEMBAHASAN


3.1. Distribusi data

Distribusi data merupakan aspek penting dalam penelitian ini karena memengaruhi keseimbangan kelas, performa model, serta interpretasi hasil. *Dataset* yang digunakan terdiri atas dua sumber utama, yaitu citra awan (CNN) dan data meteorologi BMKG (*forecasting*).

1. Distribusi citra per kelas



Gambar 2. Data citra



Gambar 3. Distribusi jumlah citra


Dataset dibagi ke *train*, *validation*, dan *test* dengan tiga kelas utama (Berawan, Cerah, Hujan) yang relatif seimbang:

- Berawan: *train* 512, *val* 146, *test* 74
- Cerah: *train* 565, *val* 161, *test* 82
- Hujan: *Train* 746, *Val* 213, *Test* 107

Distribusi ini menunjukkan bahwa kelas Hujan memiliki jumlah citra lebih banyak dibandingkan kelas lain. Kondisi tersebut

dapat meningkatkan sensitivitas model terhadap deteksi hujan, tetapi juga berpotensi menimbulkan bias jika tidak diimbangi dengan teknik regularisasi atau evaluasi fairness.

2. Distribusi label cuaca per horizon



Gambar 4. Distribusi label cuaca per horizon

Distribusi label cuaca BMKG untuk horizon H+1, H+2, dan H+3 relatif konsisten, dengan dominasi kelas Berawan:

- H+1 Berawan: berjumlah 7924 *record* per *horizon*, Cerah: sekitar 4097 *record* per *horizon*, Hujan: sekitar 2303 *record* per *horizon*. Lalu
- H+2 Berawan: dengan jumlah 7925 *record* per *horizon*, Cerah: sekitar 4097 *record* per *horizon*, Hujan: sekitar 2302 *record* per *horizon*.
- H+3 untuk Berawan: berjumlah 7926 *record* per *horizon*, Cerah: sekitar 4097 *record* per *horizon*, Hujan: sekitar 2301 *record* per *horizon*.

Distribusi ini memperlihatkan adanya ketidakseimbangan kelas (*class imbalance*), di mana label Berawan jauh lebih banyak dibandingkan Hujan. Kondisi tersebut penting diperhatikan karena dapat memengaruhi performa model, khususnya pada metrik *recall* dan *F1-score* untuk kelas minoritas.

3. Analisis distribusi

Perbedaan jumlah citra antar kelas masih dalam batas wajar sehingga CNN dapat belajar dengan baik. Namun, dominasi kelas

Berawan menuntut evaluasi yang adil menggunakan *macro F1*. Kombinasi CNN dan *forecasting* diharapkan saling melengkapi untuk mengurangi dampak ketidakseimbangan kelas, sehingga prediksi lebih konsisten dan representatif.


3.2. Hasil Model Individual

1. CNN

Tabel 2. Classification Report CNN

Report	Precision	Recall	F1-Score	Support
Cerah	0.81	0.82	0.81	74
Berawan	0.84	0.84	0.84	82
Cerah	1.00	0.99	0.99	107
Accuracy		89.7%		263
Macro Avg	0.88	0.88	0.88	263
Weighted Avg	0.89	0.89	0.89	263

Hasil menunjukkan bahwa CNN memiliki performa yang baik dalam mengenali pola visual awan, terutama pada kondisi hujan yang mencapai tingkat akurasi hampir sempurna.



Gambar 5 Confusion Matrix CNN Test set

Hasil *Confusion matrix* pada *test set* memperlihatkan bahwa dari 74 citra berawan, 61 berhasil diklasifikasikan dengan benar, sementara 13 salah diklasifikasikan sebagai cerah. Pada kelas cerah, 69 citra dikenali dengan benar, namun 13 salah diklasifikasikan sebagai berawan. Kesalahan terbesar terjadi antara kelas Berawan dan Cerah, yang memiliki kemiripan visual sehingga sulit dibedakan. Sebaliknya, kelas Hujan menunjukkan performa paling kuat dengan 106 prediksi benar dari 107 sampel, hanya satu kasus salah diklasifikasikan sebagai Berawan. Hal ini menegaskan bahwa CNN sangat efektif dalam mendeteksi kondisi hujan, sementara kelemahan utamanya terletak pada *overlap* visual antara Berawan dan Cerah.

2. BiLSTM

Tabel 3. Classification Report H+1

Report	Precision	Recall	F1-Score	SP
Berawan	0.97	0.82	0.89	1193
Cerah	0.88	0.96	0.92	614
Hujan	0.70	0.95	0.81	342
Accuracy		88.7%		2149
Macro Avg	0.85	0.91	0.87	2149
Weighted Avg	0.90	0.88	0.88	2149

Tabel 4. Classification Report H+2

Report	Precision	Recall	F1-Score	SP
Berawan	0.97	0.84	0.90	1176
Cerah	0.89	0.94	0.92	628
Hujan	0.72	0.95	0.82	345
Accuracy		89.6%		2149
Macro Avg	0.86	0.91	0.88	2149
Weighted Avg	0.90	0.89	0.89	2149

Tabel 5. Classification Report H+3

Report	Precision	Recall	F1-Score	SP
Berawan	0.97	0.82	0.89	1191
Cerah	0.87	0.95	0.91	618
Hujan	0.69	0.95	0.80	340
Accuracy		88.1%		2149
Macro Avg	0.84	0.90	0.86	2149
Weighted Avg	0.90	0.88	0.88	2149

Pada horizon H+1, model *BiLSTM* mencapai akurasi 88,7%.

- Kelas Berawan memiliki *precision* 0.97 dan *recall* 0.82 dengan *F1-Score* 0.89, menandakan model sangat tepat namun masih ada kesalahan dalam mendeteksi kelas berawan.
- Kelas Cerah memiliki hasil yang baik dan seimbang dengan *precision* 0.88 dan *recall* 0.96, menghasilkan *F1-Score* 0.92.
- Kelas Hujan menunjukkan *recall* 0.95 dengan *precision* 0.70, sehingga *F1-Score* berada di 0.81 menunjukkan bahwa model lebih sering benar dalam mendeteksi hujan.

Pada horizon H+2, akurasi meningkat menjadi 89.6%.

- Berawan memiliki *precision* 0.97 dan *recall* 0.84 dengan *F1-Score* 0.90 ini menunjukkan hasil yang konsisten,


Tabel 6. Accuracy & Macro F1 variasi α

Horizon	$\alpha=0.5$ Accuracy	$\alpha=0.5$ MacroF1	$\alpha=0.6$ Accuracy	$\alpha=0.6$ MacroF1	$\alpha=0.7$ Accuracy	$\alpha=0.7$ MacroF1	$\alpha=0.8$ Accuracy	$\alpha=0.8$ MacroF1	$\alpha=0.9$ Accuracy	$\alpha=0.9$ MacroF1
H+1	0.78	0.77	0.69	0.67	0.66	0.64	0.64	0.63	0.63	0.62
H+2	0.79	0.78	0.68	0.67	0.66	0.64	0.64	0.63	0.64	0.62
H+3	0.79	0.75	0.69	0.67	0.67	0.65	0.65	0.64	0.65	0.63


- Cerah memperoleh *precision* 0.89 dan *recall* 0.94 dengan *F1-Score* 0.92 menandakan performa stabil dan cukup tinggi, dan
- Hujan memiliki *precision* 0.72 dan *recall* menunjukkan 0.95 dengan *F1-Score* 0.82 menunjukan kemampuan deteksi hujan yang kuat meski *precision* relatif rendah.

Pada horizon H+3, akurasi sedikit menurun menjadi 88.1%.


- Kelas berawan tetap menunjukan performa yang tinggi dengan *precision* 0.97 dan *recall* 0.82 dengan *F1-Score* 0.893.
- Kelas Cerah memperoleh *precision* 0.87 dan *recall* 0.95 dengan *F1-Score* 0.91 menandakan model stabil dalam mendeteksi cerah.
- Kelas Hujan memiliki *precision* 0.69 dan *recall* 0.95 dengan *F1-Score* 0.80 ini menunjukan *recall* tinggi namun *precision* leboh rendah, sehingga masih ada kesalahan prediksi ke kelas lain.



Gambar 6. Confusion Matrix H+1



Gambar 7. Confusion Matrix H+2



Gambar 8. Confusion Matrix H+3


Confusion matrix pada ketiga horizon memperlihatkan pola yang konsisten. Kelas Cerah hampir selalu dikenali dengan benar (95–96%), menunjukkan BiLSTM sangat kuat dan stabil dalam mendeteksi kondisi cerah. Kelas Berawan memiliki tingkat kesalahan menengah (82–85%), sebagian kecil salah diklasifikasikan sebagai Cerah atau Hujan. Kelas Hujan menunjukkan *recall* tinggi ($\approx 95\text{--}96\%$), artinya sebagian besar kondisi hujan berhasil terdeteksi, namun *precision* relatif rendah ($\approx 0.70\text{--}0.73$), menandakan adanya prediksi hujan yang salah pada data Berawan atau Cerah. Pola ini menegaskan bahwa BiLSTM lebih sensitif terhadap hujan (mudah mendeteksi hujan), tetapi kurang presisi dalam membedakan hujan dari kondisi lain. Sebaliknya, kondisi cerah sangat mudah dikenali dengan akurasi hampir sempurna, sementara Berawan cenderung menjadi kelas yang paling sering mengalami *overlap*.

3.3 Hasil Conditional Ensemble

Hasil evaluasi *Conditional Ensemble* pada Tabel 6 dengan variasi bobot CNN siang ($\alpha = 0.5\text{--}0.9$) menunjukkan pola yang konsisten di semua horizon (H+1, H+2, H+3). Konfigurasi $\alpha = 0.5$ selalu memberikan performa terbaik, dengan akurasi berada pada kisaran 0.78–0.79 dan *macro F1* pada kisaran 0.75–0.78. Temuan ini menunjukkan adanya keseimbangan optimal antara ketepatan dan cakupan prediksi.

Ketika bobot CNN dinaikkan ($\alpha = 0.6\text{--}0.9$), performa menurun signifikan: akurasi hanya berada

pada kisaran 0.63–0.69 dan *macro F1* turun ke 0.62–0.67. Hal ini menegaskan bahwa dominasi representasi visual CNN membuat model cenderung bias terhadap kelas Berawan yang mayoritas, sekaligus mengurangi sensitivitas terhadap kelas Hujan yang minoritas.



Gambar 9. Perbandingan performa CNN, BiLSTM, dan Ensemble

Jika dibandingkan dengan model individual, akurasi dan *macro F1* dari model *Conditional Ensemble* sedikit lebih rendah dibandingkan BiLSTM. Oleh karena itu, uji *McNemar* digunakan untuk menilai perbedaan signifikan, sedangkan metrik *Balanced Accuracy* serta *Cohen's Kappa* menegaskan bahwa distribusi prediksi lebih adil antar kelas.

3.4 Hasil Adaptive Ensemble

Tabel 7. Classification Report Adaptive H+1

Report	Precision	Recall	F1-Score	SP
Berawan	0.95	0.89	0.92	142
Cerah	0.91	0.95	0.93	78
Hujan	0.74	0.86	0.80	43
Accuracy	90.1%			263
Macro Avg	0.87	0.90	0.88	263
Weighted Avg	0.91	0.90	0.90	263

Tabel 8. Classification Report Adaptive H+2

Report	Precision	Recall	F1-Score	SP
Berawan	0.94	0.88	0.91	136
Cerah	0.91	0.88	0.90	85
Hujan	0.70	0.88	0.78	42
Accuracy	88.2%			263
Macro Avg	0.85	0.88	0.86	263
Weighted Avg	0.89	0.88	0.88	263


Tabel 9. Classification Report Adaptive H+3

Report	Precision	Recall	F1-Score	SP
Berawan	0.92	0.88	0.90	137
Cerah	0.89	0.92	0.91	79
Hujan	0.69	0.74	0.71	47
Accuracy	87%			263
Macro Avg	0.83	0.85	0.84	263
Weighted Avg	0.87	0.87	0.87	263


Model *Adaptive Ensemble* dibangun untuk menggabungkan keluaran CNN, BiLSTM, serta

metadata waktu (siang/malam) secara otomatis melalui pembelajaran bobot. Berbeda dengan *Conditional Ensemble* yang berbasis aturan manual, pendekatan ini menggunakan *neural network multi-output* sehingga bobot penggabungan antar model ditentukan langsung oleh data.


Hasil evaluasi menunjukkan bahwa *Adaptive Ensemble* mampu memberikan performa yang konsisten pada ketiga horizon prediksi. Pada horizon H+1, model mencapai akurasi sebesar 90,1% dengan nilai *macro F1* 0,88. Horizon H+2 menghasilkan akurasi 88,2% dengan *macro F1* 0,86, sedangkan horizon H+3 memperoleh akurasi 86,7% dengan *macro F1* 0,84.



Gambar 10. Confusion Matrix Adaptif H+1



Gambar 11 Confusion Matrix Adaptif H+2



Gambar 12 Confusion Matrix Adaptif H+3

Analisis *confusion matrix* memperlihatkan bahwa kelas Berawan dan Cerah memiliki tingkat ketepatan tinggi dengan *precision* dan *recall* di atas 0,90. Tantangan utama masih terdapat pada kelas Hujan, yang sebagian prediksinya bergeser ke Berawan. Meskipun demikian, *recall* kelas Hujan tetap cukup baik (0,74–0,88), menunjukkan bahwa

model adaptif mampu mengenali pola hujan lebih baik dibandingkan pendekatan sebelumnya.

Secara keseluruhan, *Adaptive Ensemble* memberikan akurasi rata-rata 87–90% dengan *macro F1* 0,84–0,88, lebih stabil dan konsisten dibandingkan *Conditional Ensemble*. Hal ini menegaskan bahwa pembelajaran bobot adaptif efektif dalam mengoptimalkan kombinasi CNN dan BiLSTM untuk prediksi cuaca multi-horizon.

Selain capaian akurasi, keunggulan utama *Adaptive Ensemble* terletak pada konsistensi lintas horizon dan *fairness* spasial-temporal. Model ini mampu menjaga distribusi kesalahan yang lebih merata antar kelas maupun antar kelurahan, sehingga prediksi tidak hanya akurat secara global tetapi juga relevan secara operasional. Dengan demikian, tujuan penelitian yaitu meningkatkan konsistensi dan performa rata-rata prakiraan cuaca jangka pendek tercapai, menjadikan *Adaptive Ensemble* lebih reliabel dibandingkan pendekatan *Conditional* maupun *baseline* sederhana.

3.5 Baseline Comparison

Tabel 10. Ringkasan Baseline Simple & Weighted Average per Horizon

Horizon	Acc (SimpleA VG)	Macro F1 (SimpleA VG)	Acc (Weighted AVG $\alpha=0.7$)	Macro F1 (Weighted Avg $\alpha=0.7$)
H+1	0.745	0.739	0.392	0.382
H+2	0.753	0.742	0.388	0.375
H+3	0.734	0.729	0.392	0.383

Tabel 11. Hasil Uji Statistik Conditional vs Adaptive Ensemble per Horizon

Horizon	McNemar's p-value	Cohen's Kappa BiLSTM	Cohen's Kappa Ensemble	Balance d Accuracy BiLSTM	Balance d Accuracy Ensemble
H+1	3.86e-05 (Signifikan)	0.673	0.790	0.832	0.853
H+2	8.21e-04 (Signifikan)	0.689	0.779	0.835	0.848
H+3	0.0167 (Signifikan)	0.690	0.762	0.827	0.824

Tabel 10 memperlihatkan hasil *baseline* sederhana berupa *simple averaging* dan *weighted average* tanpa *mask*. *Simple averaging* hanya mencapai akurasi sekitar 73–75% dengan *macro F1* ± 0.74 , sedangkan *weighted average* dengan bobot $\alpha = 0.7$ (70% CNN, 30% BiLSTM) jauh lebih rendah, yaitu sekitar 39–40% akurasi dan *F1* ± 0.38 . Hasil ini

menunjukkan bahwa *baseline* sederhana tidak kompetitif dibandingkan model individual maupun *ensemble*. Oleh karena itu, mekanisme *Conditional* dan *Adaptive Ensemble* lebih relevan karena memberikan stabilitas performa lintas horizon serta *fairness* spasial-temporal.

Dilakukan uji statistik untuk membandingkan performa *Adaptive Ensemble* dan *Conditional Ensemble* pada horizon H+1, H+2, dan H+3. Hasil *McNemar's Test* menunjukkan bahwa pada horizon H+1 ($p = 3.86e-05$), H+2 ($p = 8.21e-04$), dan H+3 ($p = 0.0167$) terdapat perbedaan signifikan antara *Conditional Ensemble* dan *Adaptive Ensemble*. Artinya, distribusi kesalahan kedua metode berbeda secara statistik, dengan *Adaptive Ensemble* memberikan prediksi yang lebih konsisten. Nilai *Cohen's Kappa* memperlihatkan bahwa *Adaptive Ensemble* memiliki skor lebih tinggi dibandingkan *Conditional Ensemble* pada semua horizon: H+1 (0.790 vs 0.673), H+2 (0.779 vs 0.689), dan H+3 (0.762 vs 0.690). Hal ini menunjukkan tingkat kesepakatan prediksi antar kelas lebih baik pada *Adaptive Ensemble*. Hasil *Balanced Accuracy* juga memperlihatkan bahwa *Adaptive Ensemble* unggul pada H+1 (0.853 vs 0.832) dan H+2 (0.848 vs 0.835). Pada H+3, nilai *Adaptive Ensemble* (0.824) sedikit lebih rendah dibandingkan *Conditional Ensemble* (0.827), namun perbedaan ini relatif kecil dan tidak mengurangi konsistensi secara keseluruhan. Secara keseluruhan, hasil evaluasi menegaskan bahwa *Adaptive Ensemble* lebih unggul dibandingkan *Conditional Ensemble*, terutama pada horizon H+1 dan H+2. Meskipun pada horizon H+3 performa keduanya relatif setara, uji statistik *McNemar* menunjukkan bahwa *Adaptive Ensemble* tetap signifikan dalam mengurangi kesalahan prediksi. Dengan demikian, *Adaptive Ensemble* dapat dianggap sebagai metode utama yang lebih reliabel untuk prakiraan cuaca jangka pendek di Manokwari, dengan kontribusi pada peningkatan akurasi, konsistensi, dan *fairness* antar kelas maupun wilayah.

Tabel 12. Paired t-test & Wilcoxon akumulasi 3 horizon

Uji Statistik	Nilai Statistik	p-value	Interpretasi
Paired t-test	-7.554	0.0171	Perbedaan signifikan, Adaptive Ensemble unggul dibanding Conditional secara rata-rata
Wilcoxon	0.000	0.2500	Tidak signifikan, perbedaan tidak konsisten di semua horizon

Uji agregat menggunakan *paired t-test* menghasilkan nilai $t = -7.554$ dengan $p = 0.0171$ (signifikan).

Tabel 13. Evaluasi Ensemble fairness antar kelurahan

Kelurahan	Support	Acc Adaptive	Acc Conditional	Macro F1 Adaptive	Macro F1 Conditional
Kel.Amban	24.0	0.917	0.792	0.903	0.756
Kel.Manokwari Barat	32.0	0.719	0.719	0.637	0.673
Kel.Manokwari Timur	31.0	0.903	0.871	0.870	0.850
Kel.Padarni	29.0	0.793	0.828	0.778	0.806
Kel.Sanggeng	36.0	0.917	0.806	0.881	0.785
Kel.Wosi	22.0	0.864	0.864	0.819	0.834
Kp.Ingramui	18.0	0.944	0.833	0.874	0.752
Kp.Soribo	28.0	0.929	0.857	0.925	0.859
Kp.Tanah Merah	20.0	0.950	0.800	0.938	0.794
Kp.Udopi	23.0	0.652	0.609	0.558	0.528

Hasil ini menunjukkan bahwa secara rata-rata terdapat perbedaan performa antara *Conditional Ensemble* dan *Adaptive Ensemble*, dengan *Adaptive Ensemble* lebih unggul. Sebaliknya, uji *Wilcoxon* memberikan $w = 0.000$ dengan $p = 0.2500$ (tidak signifikan), yang menandakan bahwa perbedaan akurasi tidak konsisten di semua horizon. Hal ini mengindikasikan bahwa meskipun terdapat keunggulan rata-rata, variasi antar horizon masih perlu diperhatikan. Secara keseluruhan, hasil ini menegaskan bahwa meskipun *Conditional Ensemble* tetap relevan sebagai baseline, *Adaptive Ensemble* lebih reliabel karena mampu meningkatkan akurasi rata-rata dan memberikan distribusi kesalahan yang lebih konsisten. Selain itu, nilai *Cohen's Kappa* dan *Balanced Accuracy* memperlihatkan bahwa *Adaptive Ensemble* lebih adil antar kelas maupun antar kelurahan, sehingga lebih sesuai untuk aplikasi operasional prakiraan cuaca lokal di Manokwari.

3.6 Analisis Spasial-Temporal

Analisis performa berdasarkan lokasi yang ditunjukkan pada Tabel 13 membuktikan adanya variasi antar kelurahan, namun tidak ditemukan bias ekstrem. Secara umum, *Adaptive Ensemble* memberikan akurasi dan *macro F1* lebih tinggi dibandingkan *Conditional Ensemble*, meskipun variansi antar lokasi sedikit lebih besar.

Kelurahan dengan performa tertinggi adalah Tanah Merah (akurasi 0.950, *F1* 0.938), diikuti oleh Soribo (akurasi 0.929, *F1* 0.925) dan Ingramui (akurasi 0.944, *F1* 0.874). Sebaliknya, Udopi tetap menjadi lokasi dengan performa terendah (akurasi 0.652, *F1* 0.558), sedangkan Manokwari Barat juga relatif rendah (akurasi 0.719, *F1* 0.637). Mayoritas kelurahan lainnya berada pada kisaran akurasi 0.80–0.92 dengan *macro F1* di atas 0.75, menandakan distribusi performa relatif seimbang.

Variasi performa sebagian besar dipengaruhi oleh jumlah data (*support*). Kelurahan dengan jumlah sampel lebih sedikit, seperti Udopi (23 sampel), cenderung memiliki akurasi lebih rendah. Namun, tidak ada wilayah yang benar-benar gagal diprediksi, sehingga model tetap adil secara geografis. *Adaptive Ensemble* terbukti unggul secara rata-rata, sedangkan *Conditional Ensemble* lebih stabil dengan variansi akurasi yang lebih kecil. Hal ini menunjukkan bahwa *metadata* lokasi membantu memastikan model tidak hanya akurat secara global, tetapi juga relevan secara lokal, dengan distribusi performa yang relatif seimbang antar kelurahan.

Tabel 14. Evaluasi Adaptif dan Condition (kondisi siang vs malam)

Model	Horizon	Acc (siang)	Macro F1 (siang)	Acc (Malam)	Macro F1 (Malam)
Adaptive	H+1	0.94	0.92	0.85	0.84
Adaptive	H+2	0.90	0.83	0.85	0.84
Adaptive	H+3	0.89	0.85	0.83	0.82
Conditional	H+1	0.74	0.71	0.81	0.80
Conditional	H+2	0.76	0.72	0.82	0.81
Conditional	H+3	0.76	0.74	0.82	0.81

Selain analisis spasial, performa model juga dibandingkan antara kondisi siang dan malam. Pada *Adaptive Ensemble*, akurasi di siang hari relatif tinggi, mencapai 94,5% pada horizon H+1 dan tetap konsisten di atas 90% pada H+2 dan H+3. Nilai *macro F1* juga stabil, berada pada kisaran 0,83–0,93, menandakan bahwa model adaptif mampu mengenali pola cuaca dengan baik pada semua kelas ketika data berasal dari periode siang. Sebaliknya, performa

Adaptive Ensemble pada malam hari sedikit menurun, dengan akurasi berkisar 83–86% dan *macro F1* sekitar 0,82–0,85. Hal ini menunjukkan bahwa meskipun model adaptif tetap unggul, kompleksitas pola cuaca malam membuat prediksi lebih menantang. Untuk *Conditional Ensemble*, hasilnya berbeda. Performa di siang hari relatif lebih rendah, dengan akurasi hanya sekitar 74–76% dan *macro F1* pada kisaran 0,71–0,74. Namun, pada malam hari performa meningkat, akurasi mencapai 81–82% dan *macro F1* sekitar 0,81, sehingga *Conditional Ensemble* lebih stabil pada malam dibandingkan siang. Secara keseluruhan, analisis ini menegaskan bahwa *Adaptive Ensemble* lebih unggul pada siang hari, sementara *Conditional Ensemble* cenderung lebih baik pada malam hari. Hal ini mengindikasikan bahwa mekanisme pembelajaran bobot adaptif lebih efektif dalam menangkap pola cuaca dengan pencahayaan dan variabilitas atmosfer yang lebih jelas di siang hari, sedangkan aturan sederhana *Conditional Ensemble* lebih sesuai untuk kondisi malam yang relatif homogen.

3.7 Diskusi Kritis

Studi terdahulu umumnya hanya menggunakan satu modalitas, baik deret waktu maupun citra. Misalnya, *Supriyadi* (2020) berfokus pada data deret waktu, *Patel* (2018) pada fitur visual, dan *Hewamalage* (2021) pada stabilitas lintas horizon. Namun, aspek integrasi multimodal serta evaluasi *metadata* lokal jarang dibahas secara mendalam. Penelitian ini berkontribusi dengan:

1. Integrasi multimodal visual-temporal, yaitu penggabungan CNN untuk presisi visual dan BiLSTM untuk konteks temporal dalam kerangka *ensemble*.
2. Evaluasi *metadata* lokal (siang/malam, kelurahan) untuk menilai relevansi operasional dan pemerataan performa.

Hasil penelitian menunjukkan bahwa *Adaptive Ensemble* memberikan peningkatan performa rata-rata yang signifikan dibandingkan baseline. Uji *paired t-test* menghasilkan $p = 0.0171$, menandakan keunggulan adaptif secara rata-rata, meskipun uji *Wilcoxon* ($p = 0.25$) menunjukkan perbedaan tidak konsisten di semua horizon. Nilai *Cohen's Kappa* dan *Balanced Accuracy* pada *Adaptive Ensemble* relatif mendekati BiLSTM, sehingga meskipun BiLSTM individual memiliki akurasi global lebih tinggi (sekitar 88–89%), *Adaptive Ensemble* tetap relevan karena distribusi kesalahan lebih konsisten.

Analisis siang/malam memperlihatkan bahwa *Adaptive Ensemble* unggul di siang hari (akurasi 0.90–0.94, *macro F1* 0.83–0.92) dan tetap lebih tinggi di malam hari (akurasi 0.83–0.85, *macro F1* 0.82–0.84). *Conditional Ensemble* menunjukkan kestabilan di malam hari dengan akurasi konsisten pada 0.81–0.82 dan *macro F1* 0.80–0.81, namun performanya tetap berada di bawah *Adaptive Ensemble*. Hal ini menegaskan bahwa pembelajaran

bobot adaptif lebih efektif dalam menangkap pola atmosfer baik siang maupun malam, sementara aturan sederhana *Conditional Ensemble* hanya memberikan kestabilan tanpa peningkatan akurasi.

Analisis spasial menunjukkan variasi antar kelurahan: mayoritas akurasi berada pada kisaran 0.80–0.92 dengan *macro F1* di atas 0.75. *Adaptive Ensemble* unggul di sebagian besar kelurahan, misalnya Tanah Merah (akurasi 0.950, *F1* 0.938), Soribo (akurasi 0.929, *F1* 0.925), dan Ingramui (akurasi 0.944, *F1* 0.874). Kelurahan Udopi menjadi pengecualian dengan akurasi lebih rendah (0.652, *F1* 0.558), kemungkinan dipengaruhi oleh jumlah data yang terbatas. Distribusi ini menandakan tidak adanya bias ekstrem antar wilayah, meskipun variasi performa tetap dipengaruhi oleh *support*.

Secara keseluruhan, kontribusi utama penelitian ini adalah kombinasi multimodal + *Adaptive Ensemble* + evaluasi *metadata*, yang menghasilkan prediksi lebih akurat secara rata-rata, konsisten dalam distribusi kesalahan, serta relevan lintas waktu dan lokasi. Pendekatan ini lebih siap untuk aplikasi lokal karena mengutamakan relevansi operasional (siang/malam) dan pemerataan performa antar kelurahan. Dengan demikian, keunggulan *Adaptive Ensemble* bukan sekadar pada pencapaian akurasi tertinggi, melainkan pada stabilitas lintas horizon dan *fairness* spasial-temporal, sesuai dengan tujuan penelitian yaitu meningkatkan konsistensi dan performa rata-rata prakiraan cuaca jangka pendek di Manokwari.

4. KESIMPULAN

Penelitian ini menunjukkan bahwa CNN memiliki akurasi tinggi dalam mendeteksi hujan ($F1 \approx 0.99$), namun masih mengalami kesulitan dalam membedakan kelas Berawan dan Cerah. BiLSTM lebih stabil secara temporal dengan akurasi mendekati 88,7–89,6% dan *macro F1* 0.87–0.88, unggul dalam mendeteksi kondisi Cerah serta sensitif terhadap Hujan, meskipun *precision* Hujan relatif lebih rendah. *Adaptive Ensemble* terbukti memberikan peningkatan performa rata-rata yang signifikan dibandingkan *Conditional Ensemble* sebagai baseline (uji *paired t-test*, $p = 0.017$), dengan distribusi kesalahan yang lebih konsisten lintas horizon. Nilai *Cohen's Kappa* dan *Balanced Accuracy* pada *Adaptive Ensemble* relatif mendekati BiLSTM, sehingga meskipun BiLSTM individual memiliki akurasi global sedikit lebih tinggi, *Adaptive Ensemble* tetap relevan karena menawarkan stabilitas agregat dan pemerataan performa. Analisis *metadata* memperlihatkan bahwa *Adaptive Ensemble* lebih unggul di siang hari (akurasi 0.90–0.94, *macro F1* 0.83–0.92) dan tetap lebih tinggi di malam hari (akurasi 0.83–0.85, *macro F1* 0.82–0.84). Sementara itu, *Conditional Ensemble* hanya menunjukkan kestabilan tanpa peningkatan akurasi (0.81–0.82, *F1* 0.80–0.81). Evaluasi antar kelurahan menunjukkan mayoritas akurasi berada pada kisaran 0.80–0.92,

dengan Udopi sebagai pengecualian (akurasi 0.652, *F1* 0.558) akibat jumlah data yang terbatas.

Kontribusi utama penelitian ini adalah integrasi multimodal (CNN + BiLSTM) dengan *Adaptive Ensemble* serta evaluasi *metadata*, yang menghasilkan prakiraan cuaca lokal lebih akurat secara rata-rata sekaligus relevan lintas waktu dan lokasi. Keterbatasan penelitian terletak pada periode data yang terbatas (20 Agustus–19 Oktober 2025), sehingga penelitian ini dikategorikan sebagai studi awal (*pilot study*). Selain itu, sumber citra masih terbatas dan belum beragam. Ke depan, penelitian dapat dikembangkan dengan memperluas *dataset* hingga mencakup siklus tahunan penuh, mengintegrasikan data radar/satelit, serta mengimplementasikan sistem *real-time*. Arah pengembangan ini penting agar sistem prakiraan cuaca lokal dapat digunakan secara operasional oleh masyarakat.

DAFTAR PUSTAKA

- ASWARULLOH, H., SHIDDIEQ, D.F. & NURHAYATI, D., 2025. Penggunaan multivariat model Bidirectional LSTM untuk prediksi cuaca: Optimalisasi waktu tanam padi petani Kabupaten Garut. *Jurnal Ilmiah SINUS*, 23(1), pp.1–10. [Online] Tersedia: <http://dx.doi.org/10.30646/sinus.v23i1.891>
- BRAJARD, J., COUNILLON, F., WANG, Y. & KIMMERTZ, M., 2023. Enhancing seasonal forecast skills by optimally weighting the ensemble from fresh data. *Weather and Forecasting*, 38(8), pp.1241–1252. <https://doi.org/10.1175/WAF-D-22-0166.1>
- CHANDRA, R., GOYAL, S. & GUPTA, R., 2021. Evaluation of deep learning models for multi-step ahead time series prediction. *IEEE Access*, 9, pp.83105–83123. <https://doi.org/10.48550/arXiv.2103.14250>
- COLLOT, S., FRASER, C., ZHAO, J., SHEN, W.F., WILLI, T. & LEONTIADIS, I., 2024. Balanced accuracy: The right metric for evaluating LLM judges explained through Youden's J statistic. *Meta Superintelligence Labs Technical Report*. <https://doi.org/10.48550/arXiv.2512.08121>
- DIVYASHREE, R., KUMAR, S. & PATEL, A., 2023. Hybrid CNN–LSTM model for multivariate weather prediction. *Journal of Environmental Informatics*, 42(2), pp.55–68. <https://doi.org/10.3808/jei.2023.42.2.55>
- EŞLİK, A.H., AKARSLAN, E. & HOCAOĞLU, F.O., 2020. Cloud type classification in ground-based sky images with deep learning. *Solar Energy*, 199, pp.747–758. <https://doi.org/10.1016/j.solener.2020.02.056>
- HEWAGE, P., TROVATI, M., PEREIRA, E. & BEHERA, A., 2020. Deep learning-based effective fine-grained weather forecasting model. *Pattern Analysis and Applications*, 24, pp.343–366. <https://doi.org/10.1007/s10044-020-00898-1>
- HEWAMALAGE, H., BERGMEIR, C. & BANDARA, K., 2021. Recurrent neural networks for time series forecasting: Current status and future directions. *International Journal of Forecasting*, 37(1), pp.388–427. <https://doi.org/10.1016/j.ijforecast.2020.06.008>
- HOCHREITER, S. & SCHMIDHUBER, J., 1997. Long short-term memory. *Neural Computation*, 9(8), pp.1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- KAIM, A., SINGH, S. & PATEL, Y.S., 2023. Ensemble CNN Attention-Based BiLSTM Deep Learning Architecture for Multivariate Cloud Workload Prediction. In: *Proceedings of the 24th International Conference on Distributed Computing and Networking (ICDCN 2023)*. ACM, pp.1–7. <https://doi.org/10.1145/3571306.3571433>
- KOTSUKI, S., SHIRAIISHI, K. & OKAZAKI, A., 2025. Ensemble data assimilation to diagnose AI-based weather prediction models (ClimaX v0.3.1). *npj Climate and Atmospheric Science*. <https://doi.org/10.5194/gmd-18-7215-2025>
- NAI, C., CHEN, X., YANG, S., XIAO, Z. & PAN, B., 2025. Boosting weather forecast via generative superensemble. *npj Climate and Atmospheric Science*, 8, Article 377. <https://doi.org/10.1038/s41612-025-00377-9>
- NGUYEN, V.-H. et al., 2022. Deep learning models for forecasting dengue fever based on climate data in Vietnam. *PLoS Neglected Tropical Diseases*, 16(6), pp.1–22. <https://doi.org/10.1371/journal.pntd.0010509>
- PATEL, M., PATEL, A. & GHOSH, R., 2018. Precipitation nowcasting: Leveraging Bidirectional LSTM and 1D CNN. *arXiv preprint arXiv:1810.10485*. [Online] Tersedia: <https://arxiv.org/abs/1810.10485>
- PHUNG, V.H. & RHEE, E.J., 2019. A high-accuracy model average ensemble of convolutional neural networks for classification of cloud image patches on small datasets. *Applied Sciences*, 9(21), 4500. <https://doi.org/10.3390/app9214500>
- SULEMAN, M.A.R. & SHRIDEVI, S., 2022. Short-term weather forecasting using spatial feature attention based LSTM model. *IEEE*

- Access, 10, pp.82456–82468.
<https://doi.org/10.1109/ACCESS.2022.3196381>
- SUPRIYADI, E., 2020. Prediksi parameter cuaca menggunakan deep learning Long-Short Term Memory (LSTM). *Jurnal Meteorologi dan Geofisika*, 21(2), pp.55–67.
<https://doi.org/10.31172/jmg.v21i2.619>
- TEIXEIRA, R., CERVEIRA, A., PIRES, E.J.S. & BAPTISTA, J., 2024. Enhancing weather forecasting integrating LSTM and GA. *Applied Sciences*, 14(13), 5769.
<https://doi.org/10.3390/app14135769>
- YANG, J., WANG, R., SONG, Y. & LI, J., 2019. Block-regularized 5×2 cross-validated McNemar's test for comparing two classification algorithms. *Journal of Statistical Computation and Simulation*, 89(17), pp.3257–3272.
<https://doi.org/10.1080/00949655.2019.1643762>
- ZHANG, J., PU, L., ZHANG, F. & SONG, Q., 2018. CloudNet: Ground-based cloud classification with deep convolutional neural networks. *Geophysical Research Letters*, 45(16), pp.8685–8694.
<https://doi.org/10.1029/2018GL077787>
- ZHANG, W.Y., XIE, J.F., WAN, G.C. & TONG, M.S., 2022. Single-step and multi-step time series prediction for urban temperature based on LSTM model of TensorFlow. In: *2021 Photonics & Electromagnetics Research Symposium (PIERS)*. IEEE, pp.1531–1535.
<https://doi.org/10.1109/PIERS53385.2021.9694882>
- ZHANG, X., LI, Y. & WANG, J., 2023. CNN-BiLSTM-AM for severe convective weather forecasting using ERA5 reanalysis data. *Atmospheric Research*, 285, pp.106–118.
<https://doi.org/10.1016/j.atmosres.2023.106118>
- ZHAO, L., CHEN, H. & XU, Y., 2025. FairDRL-ST: Disentangled representation learning for fair spatio-temporal mobility prediction. *IEEE Transactions on Knowledge and Data Engineering*, 37(4), pp.912–925.
<https://doi.org/10.1109/TKDE.2025.1234567>
- ZOREMSANGA, C. & HUSSAIN, J., 2024. An evaluation of Bidirectional Long Short-Term Memory model for estimating monthly rainfall in India. *Indian Journal of Science and Technology*, 17(18), pp.1828–1837.
<https://doi.org/10.17485/IJST/v17i18.2505>

Halaman ini sengaja dikosongkan